


# جزوه جامع درس علوم شناختی محاسباتی

از نظریه‌های شناختی تا مدل‌های محاسباتی زبان و گفتار

تهیه شده بر اساس رونوشت جلسات کلاس

۱۸ اردیبهشت ۱۴۰۵



# فهرست مطالب

|    |                                               |       |
|----|-----------------------------------------------|-------|
| ۱  | چارچوب درس و مسئله اصلی                       | ۱     |
| ۱  | هدف درس                                       | ۱.۱   |
| ۱  | تفاوت پرسش شناختی و پرسش یادگیری ماشین        | ۲.۱   |
| ۲  | نظریه‌های شناختی به عنوان لمس بخشی از یک فیل  | ۳.۱   |
| ۲  | از هوش مصنوعی تا علوم شناختی محاسباتی         | ۴.۱   |
| ۲  | مطالعات کلاسیک، مطالعات مدرن و کیس استادی درس | ۵.۱   |
| ۳  | ارزیابی شناختی مدل‌های بزرگ                   | ۶.۱   |
| ۵  | نظریه‌های اولیه زبان و اعتبارسنجی شناختی      | ۲     |
| ۵  | Cohort Model: از صدا به کلمه                  | ۱.۲   |
| ۶  | TRACE: نقش انتظار و context                   | ۲.۲   |
| ۶  | اعتبارسنجی نظریه‌های شناختی                   | ۳.۲   |
| ۷  | معماری شناختی و حافظه                         | ۳     |
| ۷  | چرا معماری شناختی لازم است؟                   | ۱.۳   |
| ۷  | مثال جارو رباتیک                              | ۲.۳   |
| ۸  | انواع حافظه                                   | ۳.۳   |
| ۸  | حافظه کوتاه مدت و حافظه کاری                  | ۱.۳.۳ |
| ۸  | حافظه بلند مدت                                | ۲.۳.۳ |
| ۸  | نسبت Chain of Thought با حافظه                | ۳.۳.۳ |
| ۸  | اختلالات و اعتبارسنجی تقسیم بندی حافظه        | ۴.۳   |
| ۹  | ACT و ACT-R                                   | ۵.۳   |
| ۱۰ | انتقال از حافظه کوتاه مدت به بلند مدت         | ۶.۳   |

|       |                                                        |    |
|-------|--------------------------------------------------------|----|
| ۷.۳   | نگاشت اجزا به مغز . . . . .                            | ۱۰ |
| ۸.۳   | اعتبارسنجی معماری شناختی . . . . .                     | ۱۰ |
| ۴     | حافظه کاری، بار شناختی و مدل‌های زبانی                 | ۱۳ |
| ۱.۴   | Cognitive Load Theory . . . . .                        | ۱۳ |
| ۲.۴   | عدد $7 \pm 2$ و مفهوم Chunk . . . . .                  | ۱۳ |
| ۳.۴   | حافظه کوتاه مدت و بلندمدت در LLM . . . . .             | ۱۳ |
| ۴.۴   | Multi-Hop Reasoning . . . . .                          | ۱۴ |
| ۵.۴   | دو نوع فشار حافظه‌ای در LLM . . . . .                  | ۱۴ |
| ۱.۵.۴ | Context Saturation . . . . .                           | ۱۴ |
| ۲.۵.۴ | Attentional Residue . . . . .                          | ۱۴ |
| ۳.۵.۴ | طراحی آزمایش برای محدودیت حافظه کاری . . . . .         | ۱۴ |
| ۴.۵.۴ | تکامل آزمون‌های هوش مصنوعی . . . . .                   | ۱۵ |
| ۶.۴   | راهکار شناختی: Divide and Conquer و Chunking . . . . . | ۱۵ |
| ۵     | ترنسفورمر، توجه و حافظه کاری                           | ۱۷ |
| ۱.۵   | حافظه در Transformer . . . . .                         | ۱۷ |
| ۲.۵   | Contextual Embedding . . . . .                         | ۱۷ |
| ۳.۵   | Query, Key, Value . . . . .                            | ۱۸ |
| ۴.۵   | آیا کافی است attention را بزرگ‌تر کنیم؟ . . . . .      | ۱۸ |
| ۵.۵   | Local Attention . . . . .                              | ۱۸ |
| ۶.۵   | Mixture of Experts و Multi-Head Attention . . . . .    | ۱۹ |
| ۶     | سوگیری شناختی و سه نظریه توضیح‌دهنده                   | ۲۱ |
| ۱.۶   | تعریف Cognitive Bias . . . . .                         | ۲۱ |
| ۲.۶   | انتخاب خط پژوهشی . . . . .                             | ۲۱ |
| ۳.۶   | نمونه‌ها . . . . .                                     | ۲۲ |
| ۱.۳.۶ | Confirmation Bias . . . . .                            | ۲۲ |
| ۲.۳.۶ | Anchoring Bias . . . . .                               | ۲۲ |
| ۳.۳.۶ | Halo Effect . . . . .                                  | ۲۲ |

|       |                                                   |    |
|-------|---------------------------------------------------|----|
| ۴.۶   | آیا bias همیشه بد است؟                            | ۲۲ |
| ۵.۶   | توضیح اول: Cognitive Load Theory                  | ۲۲ |
| ۶.۶   | توضیح دوم: Dual Process Theory                    | ۲۳ |
| ۷.۶   | رفتار شبیه سیستم ۲ در LLM                         | ۲۳ |
| ۸.۶   | توضیح سوم: Predictive Coding                      | ۲۴ |
| ۷     | <b>Predictive Coding، بیز و مدل‌های عصبی</b>      | ۲۵ |
| ۱.۷   | Prior، Likelihood و Posterior                     | ۲۵ |
| ۲.۷   | Precision                                         | ۲۵ |
| ۳.۷   | چه زمانی belief update نمی‌شود؟                   | ۲۶ |
| ۴.۷   | وقتی خطا وجود دارد، سیستم چه می‌کند؟              | ۲۶ |
| ۵.۷   | کاهش bias در LLM با این چارچوب                    | ۲۶ |
| ۶.۷   | تفاوت با شبکه‌های عصبی رایج                       | ۲۷ |
| ۷.۷   | آیا GAN شبیه Predictive Coding است؟               | ۲۷ |
| ۸.۷   | پردازنده‌های Neuromorphic                         | ۲۷ |
| ۸     | <b>توجه انتخابی</b>                               | ۲۹ |
| ۱.۸   | حافظه حسی و گلوگاه توجه                           | ۲۹ |
| ۲.۸   | Broadbent's Filter Theory: انتخاب زود هنگام       | ۲۹ |
| ۳.۸   | Late Selection                                    | ۳۰ |
| ۴.۸   | Perceptual Load Theory                            | ۳۰ |
| ۵.۸   | Treisman's Attenuation Theory                     | ۳۱ |
| ۶.۸   | پردازش سری و موازی                                | ۳۱ |
| ۹     | <b>پردازش گفتار و نگاشت توجه انتخابی به ماشین</b> | ۳۳ |
| ۱.۹   | دستیار صوتی و Wake Word                           | ۳۳ |
| ۲.۹   | تولید گفتار انسان                                 | ۳۳ |
| ۳.۹   | از موج خام تا ویژگی                               | ۳۴ |
| ۱.۳.۹ | Raw Wave                                          | ۳۴ |
| ۲.۳.۹ | Sampling                                          | ۳۴ |

|    |                                                  |        |
|----|--------------------------------------------------|--------|
| ۳۴ | Windowing و Framing                              | ۳.۳.۹  |
| ۳۴ | Spectrogram و Fourier Transform                  | ۴.۳.۹  |
| ۳۴ | Formants                                         | ۵.۳.۹  |
| ۳۵ | MFCC                                             | ۴.۹    |
| ۳۵ | کاربرد در طبقه‌بندی                              | ۵.۹    |
| ۳۷ | <b>مدل‌های گفتاری: wav2vec، HuBERT و Whisper</b> | ۱۰     |
| ۳۷ | آیا همیشه باید گفتار به متن تبدیل شود؟           | ۱.۱۰   |
| ۳۷ | سه جزء سیستم گفتاری                              | ۲.۱۰   |
| ۳۸ | ویژگی‌های learnable و deterministic              | ۳.۱۰   |
| ۳۸ | Self-Supervised Learning در گفتار                | ۴.۱۰   |
| ۳۸ | wav2vec 2.0                                      | ۵.۱۰   |
| ۳۸ | Quantization و Codebook                          | ۱.۵.۱۰ |
| ۳۹ | HuBERT                                           | ۶.۱۰   |
| ۳۹ | Whisper                                          | ۷.۱۰   |
| ۳۹ | چرا Encoder-Decoder؟                             | ۱.۷.۱۰ |
| ۳۹ | Cross-Attention و Masked Self-Attention          | ۲.۷.۱۰ |
| ۴۰ | ایده پژوهشی از توجه انتخابی                      | ۸.۱۰   |
| ۴۱ | <b>سیستم پاداش و یادگیری تقویتی</b>              | ۱۱     |
| ۴۱ | پاداش در مغز                                     | ۱.۱۱   |
| ۴۱ | دو مسیر مهم                                      | ۲.۱۱   |
| ۴۱ | Mesolimbic Pathway                               | ۱.۲.۱۱ |
| ۴۲ | Mesocortical Pathway                             | ۲.۲.۱۱ |
| ۴۲ | ارتباط با Reinforcement Learning                 | ۳.۱۱   |
| ۴۳ | <b>پروژه، تمرین‌ها و جمع‌بندی مسیر پژوهشی</b>    | ۱۲     |
| ۴۳ | مسیر پژوهشی پیشنهادی درس                         | ۱.۱۲   |
| ۴۳ | نمونه‌های موضوع پروژه                            | ۲.۱۲   |
| ۴۵ | جمع‌بندی کل درس تا اینجا                         | ۳.۱۲   |

# فصل ۱

## چارچوب درس و مسئله اصلی

### ۱.۱ هدف درس

موضوع درس، علوم شناختی محاسباتی (Computational Cognitive Science) است. علوم شناختی می‌پرسد انسان چگونه می‌بیند، می‌شنود، حرف می‌زند، فکر می‌کند، تصمیم می‌گیرد، خطا می‌کند و یاد می‌گیرد. علوم شناختی محاسباتی یک گام جلوتر می‌رود و می‌پرسد چگونه می‌توان این فرایندها را به صورت محاسباتی، صوری و قابل پیاده‌سازی مدل کرد.

در این درس، تمرکز اصلی روی پیوند میان علوم شناختی و هوش مصنوعی است؛ به ویژه:

- پردازش زبان طبیعی (NLP)
- استدلال (Reasoning)
- پردازش گفتار (Speech Processing)
- مدل‌های زبانی بزرگ (Large Language Models / LLMs)
- ترنسفورمر (Transformer)

مسیر کلی درس این است که ابتدا یک نظریه شناختی را بفهمیم، سپس ببینیم مدل‌های یادگیری ماشین یا یادگیری عمیق در همان مهارت چه محدودیتی دارند، و در نهایت بررسییم آیا آن نظریه شناختی می‌تواند ایده‌ای برای بهبود مدل بدهد یا نه.

### ۲.۱ تفاوت پرسش شناختی و پرسش یادگیری ماشین

در یادگیری ماشین، پرسش معمولاً چنین است:

چگونه این task را با accuracy بهتر حل کنیم؟

اما در علوم شناختی، پرسش اصلی این است:

انسان چگونه این task را انجام می‌دهد؟

اگر یک مدل خروجی درست بدهد، هنوز لزوماً مدل شناختی خوبی نیست. مدل شناختی باید بتواند فرایند، خطاها، تفاوت‌های فردی و گاهی اختلالات انسانی را هم توضیح دهد. به همین دلیل در علوم شناختی، فقط نتیجه مهم نیست؛ مسیر رسیدن به نتیجه نیز اهمیت دارد.

### ۳.۱ نظریه‌های شناختی به عنوان لمس بخشی از یک فیل

استاد برای توضیح تعدد نظریه‌های شناختی از استعاره فیل استفاده کرد: هر نظریه بخشی از پدیده شناخت انسان را توضیح می‌دهد. یک نظریه ممکن است شنیدن را توضیح دهد، دیگری حافظه را، دیگری توجه را و دیگری سوگیری شناختی را. هیچ نظریه‌ای به تنهایی کل ذهن انسان را توضیح نمی‌دهد.

یک نظریه شناختی خوب باید بتواند:

- رفتار درست و خطاهای انسان را توضیح دهد.
- فقط مخصوص یک گروه محدود نباشد.
- درباره کودک، سالمند، فرد سالم، فرد دارای اختلال و افراد با توانایی‌های متفاوت حرفی برای گفتن داشته باشد.
- آزمایش‌پذیر باشد و پیش‌بینی تولید کند.

### ۴.۱ از هوش مصنوعی تا علوم شناختی محاسباتی

مسیر دانشی درس را می‌توان چنین دید:

AI → Machine Learning → Deep Learning → Computational Cognitive Science

در AI کلاسیک با جست‌وجو، برنامه‌ریزی، الگوریتم‌های ژنتیک و روش‌هایی مثل BFS یا simulated annealing روبه‌رو می‌شویم. در یادگیری ماشین، مدل از داده یاد می‌گیرد. در یادگیری عمیق، بازنمایی‌های پیچیده‌تر و معماری‌های عمیق‌تر ساخته می‌شوند. در علوم شناختی محاسباتی می‌پرسیم: کدام مهارت شناختی در این مدل‌ها غایب است و چگونه می‌توان آن را اضافه کرد؟

### ۵.۱ مطالعات کلاسیک، مطالعات مدرن و کیس‌استادی درس

در کلاس توضیح داده شد که بسیاری از درس‌های رایج علوم شناختی محاسباتی، به‌ویژه در کورس‌های دانشگاهی، مدت زیادی روی vision و پردازش تصویر تمرکز داشته‌اند؛ چون هم داده و آزمایش‌های کلاسیک زیادی در این حوزه وجود

دارد و هم تاریخ هوش مصنوعی نیز رشد مهمی را از بینایی ماشین تجربه کرده است. در این درس، کیس استادی اصلی بیشتر به زبان، گفتار، استدلال و مدل‌های زبانی نزدیک شد تا ارتباط مستقیم‌تری با دانشجویان هوش مصنوعی داشته باشد.

منابع درس دو جنس دارند:

- مقاله‌ها و نظریه‌های کلاسیک شناختی، مثل مدل‌های تشخیص گفتار، حافظه، توجه و سوگیری.
  - مقاله‌های مدرن هوش مصنوعی که یک ضعف شناختی در مدل‌های عمیق یا مدل‌های زبانی را نشان می‌دهند و سپس برای آن راه حل محاسباتی پیشنهاد می‌کنند.
- بنابراین خواندن مقاله در این درس فقط برای دانستن یک روش فنی نیست؛ هدف این است که دانشجو بتواند بین نظریه شناختی، طراحی آزمایش، داده انسانی و معماری محاسباتی پل بزند.

## ۶.۱ ارزیابی شناختی مدل‌های بزرگ

یکی از بحث‌های مهم جلسه اول این بود که مدل‌های بزرگ ممکن است در benchmarkهای معمول خوب عمل کنند، اما در مهارت‌هایی مثل قیاس، تعمیم انتزاعی و counterfactual reasoning شکست بخورند. مثال کلاس، آزمون‌های قیاسی با الفبای ساختگی بود: اگر مدل فقط ترتیب الفبای آشنا را حفظ کرده باشد، با تغییر نمادها یا برعکس کردن ترتیب، ممکن است نتواند مفهوم انتزاعی «بعدی بودن» را منتقل کند.

در آزمون‌های قیاس داستانی نیز ممکن است دو داستان از نظر سطحی بسیار متفاوت باشند، اما theme مشترکی داشته باشند؛ مثلاً هر دو درباره کمک کردن باشند. انسان معمولاً می‌تواند قیاس‌های دورتر را از راه رابطه عمیق‌تر بفهمد، اما مدل ممکن است فقط شباهت‌های سطحی را دنبال کند.

برای ارزیابی شناختی مدل، دو معیار جدا باید بررسی شود:

- آیا مدل task را درست انجام می‌دهد؟
- آیا الگوی خطا و سختی مدل با الگوی خطا و سختی انسان correlation دارد؟

در همین چارچوب، استاد به بحث هوش مصنوعی عمومی (Artificial General Intelligence) و دسته‌بندی مهارت‌های شناختی نیز اشاره کرد. چارچوب‌هایی مثل Cattell-Horn-Carroll می‌توانند برای تعریف انواع توانایی شناختی و طراحی آزمون‌های مقایسه‌ای بین انسان و مدل استفاده شوند.

اگر هدف ساختن یک ابزار بهتر از انسان باشد، می‌خواهیم خطاهای انسانی را کاهش دهیم. اما اگر هدف مدل‌سازی شناخت انسان باشد، شباهت الگوی خطا اهمیت مرکزی دارد. مسیر پژوهشی پیشنهادی کلاس این بود: نخست نشان دهیم انسان و مدل در یک خطای شناختی مشترک‌اند، سپس با نظریه شناختی آن خطا را توضیح دهیم و در نهایت با RAG, prompting, fine-tuning یا تغییر معماری آن را هدفمند کاهش دهیم.

### نکات اجرایی جلسه اول

- دانشجویان باید در گروه Bale درس عضو شوند.
- هر دانشجو باید یک بیوگرافی یا رزومه کوتاه برای استاد ارسال کند: دانشگاه قبلی، معدل، استاد راهنما، خط

پژوهشی، سابقه پژوهشی و علایق مرتبط.

- فایل‌های Excalidraw هر جلسه در اختیار دانشجویان قرار می‌گیرد و مبنای پیگیری تصویری کلاس است.

## فصل ۲

# نظریه‌های اولیهٔ زبان و اعتبارسنجی شناختی

### ۱.۲ Cohort Model: از صدا به کلمه

مدل Cohort (Cohort Model) یکی از نظریه‌های کلاسیک در تشخیص کلمهٔ گفتاری است. ایدهٔ اصلی آن این است که وقتی بخشی از یک کلمه را می‌شنویم، مجموعه‌ای از کلمات ممکن در ذهن فعال می‌شوند. هرچه صدای بیشتری دریافت می‌شود، گزینه‌های ناسازگار حذف می‌شوند تا در نهایت کلمهٔ مناسب انتخاب شود.

مثلاً در رستوران، اگر صدایی با «ب» آغاز شود، گزینه‌هایی مثل «برنج» یا «بریانی» فعال می‌شوند. اگر صدای بعدی «ر» باشد، لیست محدودتر می‌شود. این فرایند شبیه پیشنهادهاى تکمیل خودکار است، اما در ذهن انسان رخ می‌دهد.

برای فهم بهتر، cohort را می‌توان «گروه نامزدها» دانست. در لحظهٔ شنیدن اولین بخش صوتی، ذهن هنوز نمی‌داند کلمهٔ نهایی چیست، پس چند نامزد را فعال نگه می‌دارد. با رسیدن هر قطعهٔ صوتی جدید، نامزدهایی که دیگر با ورودی سازگار نیستند حذف می‌شوند. بنابراین مدل توضیح می‌دهد چرا ابتدای کلمه در تشخیص گفتار بسیار مهم است و چرا نویز یا ابهام در همان ابتدا می‌تواند مسیر انتخاب کلمه را عوض کند.

#### ویژگی اصلی Cohort

جریان اطلاعات عمدتاً پایین‌به‌بالا (bottom-up) است:

انتخاب کلمه → کلمات ممکن → صدا

محدودیت این مدل آن است که انسان همیشه مثل یک autocomplete ساده عمل نمی‌کند. اگر فقط جریان پایین‌به‌بالا وجود داشته باشد، انتظار قبلی، موقعیت، موضوع گفت‌وگو و دانش زبانی نباید نقش زیادی داشته باشند؛ در حالی که در تجربهٔ واقعی، همین عوامل می‌توانند شنیدن یک صدای مبهم را تغییر دهند.

## ۲.۲ TRACE: نقش انتظار و context

مدل TRACE (TRACE Model) دیدگاه تعاملی تری ارائه می‌کند. در این مدل، فقط صدا تعیین‌کننده نیست؛ انتظار، context و دانش قبلی نیز روی تفسیر صدا اثر می‌گذارند. اگر بخشی از صدا مبهم باشد، ذهن می‌تواند با توجه به context آن را کامل کند.

تفاوت اصلی:

- در Cohort: آنچه می‌شنویم، گزینه‌ها را محدود می‌کند.
  - در TRACE: آنچه می‌شنویم و آنچه انتظار داریم بشنویم، هم‌زمان اثر می‌گذارند.
- پس TRACE صرفاً رد کردن Cohort نیست؛ بیشتر یک گام تکاملی است. Cohort جنبه مهمی از تشخیص گفتار را می‌گیرد، اما TRACE نشان می‌دهد پردازش گفتار تعاملی است: اطلاعات صوتی از پایین به بالا می‌آید و انتظار معنایی/زبانی از بالا به پایین روی تفسیر آن اثر می‌گذارد. این همان الگوی کلی بسیاری از نظریه‌های شناختی است: نظریه قبلی بخشی از پدیده را خوب توضیح می‌دهد، سپس نظریه جدید تلاش می‌کند بخش‌های جاافتاده را اضافه کند.

## ۳.۲ اعتبارسنجی نظریه‌های شناختی

یک نظریه شناختی فقط با مثال قانع‌کننده معتبر نمی‌شود. باید با آزمایش‌های مستقل، داده انسانی، تحلیل آماری و گاهی داده مغزی سنجیده شود. ویژگی‌های آزمایش خوب:

- روی افراد متنوع انجام شود.
  - فقط پاسخ درست را نسنجد؛ خطاها را هم توضیح دهد.
  - به یک سن، یک وضعیت یا یک گروه بسیار خاص محدود نباشد.
  - اختلالات و تفاوت‌های شناختی را هم در نظر بگیرد.
  - در شرایط و آزمایش‌های مختلف قابل تکرار باشد.
  - بتواند پیش‌بینی‌های جدید تولید کند.
- برای نمونه، اگر کسی به جای «برنج» کلمه‌ای دیگر بشنود، نظریه باید بتواند توضیح دهد این خطا از کجا آمده است: نویز صوتی، context، انتظار قبلی، یا محدودیت توجه.

## فصل ۳

# معماری شناختی و حافظه

### ۱.۳ چرا معماری شناختی لازم است؟

اگر بخواهیم چند نظریه شناختی را در یک سیستم هوش مصنوعی وارد کنیم، باید بدانیم جریان اطلاعات چگونه میان آن‌ها حرکت می‌کند. ورودی کجا می‌رود؟ حافظه کجا وارد می‌شود؟ کدام ماژول تصمیم می‌گیرد؟ عمل چگونه تولید می‌شود؟ پاسخ این پرسش‌ها همان معماری شناختی (Cognitive Architecture) است.

#### تعریف معماری شناختی

معماری شناختی یعنی مدل کردن فرایندهای شناختی انسان در قالب یک سیستم یکپارچه که ماژول‌هایی مانند ادراک، حافظه، بازیابی، تصمیم‌گیری و عمل در آن با هم تعامل دارند.

یک معماری شناختی باید تا حدی با مغز قابل نگاشت باشد؛ مثلاً اگر ماژول بینایی دارد، باید بتوان گفت با نواحی بینایی مثل occipital lobe متناظر است. اگر حافظه اعلانی دارد، باید نسبت آن با hippocampus توضیح داده شود.

### ۲.۳ مثال جارو رباتیک

فرض کنید ربات جاروبرقی با یک فنجان پر از آب روبه‌رو می‌شود. یک مدل ساده ممکن است فقط مانع را کنار بزند، اما انسان چنین کاری نمی‌کند؛ چون می‌داند فنجان ممکن است بشکند، آب ممکن است بریزد و زمین خیس شود.

برای رفتار انسانی‌تر، ربات به چیزهایی بیشتر از تشخیص شیء نیاز دارد:

- دانش عامه (common-sense knowledge)

- حافظه کوتاه‌مدت برای نگه‌داشتن وضعیت فعلی

- حافظه اعلانی برای دانستن facts

- حافظه رویه‌ای برای اجرای مهارت‌ها

- انتخاب عمل و بازخوردگیری از عمل قبلی

### ۳.۳ انواع حافظه

در کلاس، حافظه ابتدا به دو دسته اصلی تقسیم شد:

#### ۱.۳.۳ حافظه کوتاه مدت و حافظه کاری

حافظه کوتاه مدت (Short-Term Memory) یا حافظه کاری (Working Memory) یک فضای محدود و موقت برای نگهداری و پردازش اطلاعات فعلی است. مثال ساده، نگه داشتن یک شماره تلفن برای چند ثانیه است.

#### ۲.۳.۳ حافظه بلندمدت

حافظه بلندمدت (Long-Term Memory) پایدارتر است و خود به دو دسته مهم تقسیم می شود:

- حافظه اعلانی (Declarative Memory): facts و دانش صریح؛ مثل اینکه آب زمین را خیس می کند.
- حافظه رویه ای (Procedural Memory): مهارت ها و procedure؛ مثل رانندگی، آشپزی یا حرکت دادن بازوی ربات.

#### ۳.۳.۳ نسبت Chain of Thought با حافظه

در کلاس تأکید شد که Chain of Thought را نباید مستقیماً معادل حافظه رویه ای دانست. CoT بیشتر به آشکار کردن یا هدایت گام های استدلال کمک می کند و به بازیابی دانش اعلانی و reasoning نزدیک تر است. ممکن است اجرای یک روش مرحله به مرحله به استفاده از مهارت های رویه ای هم کمک کند، اما خود آن یک مدل کامل از حافظه رویه ای انسان نیست.

### ۴.۳ اختلالات و اعتبارسنجی تقسیم بندی حافظه

یک نظریه شناختی وقتی قوی تر می شود که بتواند اختلالات را نیز توضیح دهد. اگر نظریه می گوید حافظه به کوتاه مدت، بلندمدت، اعلانی و رویه ای تقسیم می شود، باید بتواند نشان دهد کدام اختلال با کدام بخش سازگارتر است.


برای مثال، استرس می تواند بازیابی حافظه اعلانی را مختل کند: فرد چیزی را می داند، اما در لحظه نمی تواند آن را توضیح دهد یا به یاد آورد. اگر استرس روی خود عمل گفتار، لکنت یا اجرای مهارت اثر بگذارد، می توان بخشی از آن را به حافظه

رویه‌ای نیز ربط داد. در پارکینسون، به‌ویژه در مراحل اولیه، اختلال‌های حرکتی و مهارت‌های رویه‌ای برجسته‌ترند و با مدارهایی مثل basal ganglia سازگارند؛ هرچند در مراحل بعدی ممکن است کارکردهای شناختی دیگر نیز درگیر شوند.

## ۵.۳ ACT و ACT-R

معماری ACT از کارهای John R. Anderson در دهه ۱۹۷۰ آغاز شد. نسخه‌های بعدی، به‌ویژه ACT-R، تلاش می‌کنند ساختار حافظه، تولید عمل و نگاشت به مغز را دقیق‌تر مدل کنند.

در یک تصویر ساده‌شده از ACT-R برای جارو رباتیک، اجزا چنین‌اند:



بازگشت خروجی production execution به حافظه کاری مهم است، چون سیستم باید بداند چه عملی انجام داده تا دنباله اعمال از هم گسسته نشود.

در این معماری، حافظه اعلانی فقط یک مخزن داده نیست؛ می‌تواند به توضیح‌پذیری هم کمک کند. اگر ربات مسیرش را عوض کند، دانش اعلانی می‌تواند توضیحی از جنس «فنجان پر از آب شکستی و در مسیر بود» فراهم کند. حافظه رویه‌ای نیز معمولاً به شکل قاعده‌های if-then یا production rule فهمیده می‌شود؛ مثلاً «اگر مانع شکستی و پرخطر در مسیر بود، سرعت را کم کن یا مسیر را تغییر بده».

### ۶.۳ انتقال از حافظه کوتاه مدت به بلند مدت

اطلاعات معمولاً با تمرین، تکرار و استفاده از حافظه کوتاه مدت به حافظه بلند مدت منتقل می‌شوند، اما کلاس روی چند عامل شتاب‌دهنده نیز تأکید کرد:

- احساس شدید، مثل حادثه، ترس، شادی بزرگ یا تولد فرزند.
  - تعجب و غیرمنتظره بودن؛ به همین دلیل تجربه آموزشی متفاوت می‌تواند ماندگارتر شود.
  - تمایز و برجستگی؛ چیزی که از زمینه معمول جدا باشد راحت‌تر به خاطر می‌ماند.
  - علامت‌گذاری، تصویرسازی ذهنی، ساخت مثال و پیدا کردن ارتباط بین مفاهیم.
- از منظر آموزشی، پرسش مهم این است که چگونه می‌توان یادگیری را طوری طراحی کرد که اطلاعات مهم سریع‌تر و پایدارتر وارد حافظه بلند مدت شوند.

### ۷.۳ نگاشت اجزا به مغز

| نگاشت تقریبی مغزی | ماژول شناختی                                                  |
|-------------------|---------------------------------------------------------------|
| Occipital lobe    | ماژول بینایی                                                  |
| Frontal lobe      | ماژول حرکتی                                                   |
| Prefrontal cortex | تصمیم‌گیری و reasoning                                        |
| Hippocampus       | حافظه اعلانی                                                  |
| Basal ganglia     | حافظه رویه‌ای                                                 |
|                   | بخش‌هایی از Frontal lobe بیشتر با Prefrontal cortex مرتبط است |
|                   | Hippocampus و شبکه‌های مرتبط                                  |
|                   | Basal ganglia و مدارهای حرکتی-یادگیری                         |

این نگاشت‌ها دقیق و جدا از هم نیستند. مغز شبکه‌ای و تعاملی عمل می‌کند، اما همین نگاشت تقریبی برای اعتبارسنجی معماری شناختی مهم است.

### ۸.۳ اعتبارسنجی معماری شناختی

اگر یک معماری ادعا کند شبیه انسان پردازش می‌کند، باید فقط خروجی آن با انسان مقایسه نشود. باید sequence فعال شدن ماژول‌ها نیز با داده انسانی مقایسه شود. مثلاً در یک task بینایی، می‌توان از EEG، fMRI، زمان واکنش یا eye-tracking استفاده کرد و بررسی کرد آیا جریان فعالیت انسان با جریان ماژول‌های مدل سازگار است یا نه.

#### فاز اول پروژه: پیدا کردن dataset شناختی

دانشجویان باید dataset پیدا کنند که برای مدل‌سازی معماری شناختی مناسب باشد. dataset خوب بهتر است شامل ورودی، خروجی یا عمل انسان، و در صورت امکان sequence، زمان واکنش، EEG، fMRI، مسیر نگاه یا

گزارش فرایند حل مسئله باشد. خروجی مورد انتظار یک سند کوتاه بود: معرفی dataset، ورودی انسان، خروجی یا رفتار انسان، وجود یا نبود سیگنال مغزی/رفتاری/زمانی، امکان دادن همان ورودی به مدل، task قابل انجام و روش مقایسه انسان و مدل. تمرین می‌توانست دو نفره باشد و تحویل آن از طریق LMS انجام شود. در رونوشت جلسه، تاریخ دقیق ددلاین کمی نامطمئن بود و به حوالی جلسه یکشنبه اشاره شده بود.



## فصل ۴

# حافظه کاری، بار شناختی و مدل‌های زبانی

### ۱.۴ Cognitive Load Theory

نظریه بار شناختی (Cognitive Load Theory) بر محدودیت حافظه کاری تأکید دارد. انسان نمی‌تواند در هر لحظه همه اطلاعات محیط یا همه شاخه‌های یک مسئله را پردازش کند. بنابراین باید اطلاعات را انتخاب، سازمان‌دهی و فشرده کند.

### ۲.۴ عدد $7 \pm 2$ و مفهوم Chunk

مقاله معروف The Magical Number Seven, Plus or Minus Two از George Miller در سال ۱۹۵۶ نشان داد که ظرفیت پردازش فوری انسان محدود است. اما واحد حافظه لزوماً یک حرف یا عدد منفرد نیست؛ واحد مهم **chunk** (Chunk) است.

اگر عددهای ۱ ۳ ۶ ۹ را جدا ببینیم، چهار آیتم‌اند. اما اگر آن را سال ۱۳۶۹ بدانیم، کل آن می‌تواند یک chunk شود. بنابراین chunking به حافظه بلندمدت وابسته است: دانش قبلی کمک می‌کند اطلاعات جدید را فشرده‌تر نگه داریم.

#### دقت مفهومی

در ادبیات جدیدتر، عدد  $7 \pm 2$  قانون ثابت همه انسان‌ها نیست. پیام اصلی این است که حافظه کاری محدود است و عملکرد به نوع اطلاعات، chunking، تمرین، تخصص و شرایط فرد بستگی دارد.

### ۳.۴ حافظه کوتاه‌مدت و بلندمدت در LLM

در مدل‌های زبانی بزرگ:

- حافظه بلندمدت را می‌توان تقریباً معادل وزن‌ها و پارامترهای آموزش دیده دانست.

- حافظه کوتاه مدت یا کاری را می توان تقریباً معادل prompt و context window دانست.

- RAG می تواند مانند حافظه بلند مدت خارجی عمل کند.

این تشبیه کامل نیست، اما برای تحلیل محدودیت های مدل مفید است. وقتی prompt طولانی، پرنویز یا متناقض شود، مدل ممکن است مانند انسانی با بار شناختی بالا دچار افت عملکرد شود.

## ۴.۴ Multi-Hop Reasoning

در استدلال چند مرحله ای (Multi-Hop Reasoning) پاسخ نهایی به چند قطعه اطلاعات و چند گام استدلال وابسته است. مدل باید اطلاعات را نگه دارد، ارتباط دهد، نتیجه میانی بسازد و از آن برای گام بعدی استفاده کند. به همین دلیل این task برای سنجش حافظه کاری مدل مناسب است.

## ۵.۴ دو نوع فشار حافظه ای در LLM

### ۱.۵.۴ Context Saturation

در Context Saturation اطلاعات مهم در میان حجم زیادی از نویز پخش می شود. با افزایش نویز، مدل ممکن است نتواند داده مرتبط را پیدا کند و success rate کاهش یابد.

### ۲.۵.۴ Attentional Residue

در Attentional Residue اثر اطلاعات یا task های قبلی روی task فعلی باقی می ماند. مدل ممکن است سؤال جدید را با زمینه قبلی قاطی کند. در تجربه عملی، گاهی reset کردن مکالمه یا بازنویسی prompt همین مشکل را کم می کند.

## ۳.۵.۴ طراحی آزمایش برای محدودیت حافظه کاری

برای نشان دادن محدودیت حافظه کاری مدل، فقط طولانی کردن prompt کافی نیست. در کلاس چند طراحی آزمایشی مطرح شد: اضافه کردن نویز بین اطلاعات مرتبط، پخش کردن شواهد لازم در بخش های دور از هم، ارجاع به بخش های قبلی مکالمه، تغییر خواسته پس از ارائه یک دستور یا کد، و قرار دادن یک task مزاحم قبل از task اصلی. اگر مدل با افزایش نویز یا تغییر ترتیب شواهد افت کند، می توان گفت مشکل فقط اندازه context window نیست؛ مدیریت توجه و بازیابی اطلاعات نیز محدود است.

## ۴.۵.۴ تکامل آزمون‌های هوش مصنوعی

در ابتدا آزمون‌هایی مثل Turing Test یا معیارهای کلاسیک accuracy, precision و recall کافی به نظر می‌رسیدند. سپس مسئله تعمیم خارج از توزیع (Out-of-Distribution Generalization) مهم شد. اکنون یکی از مسیرهای جدی، آزمون‌های شناختی است: آیا مدل مانند انسان محدودیت حافظه کاری دارد؟ آیا با بار شناختی، نویز، جابه‌جایی توجه یا قیاس دور دچار خطای مشابه می‌شود؟

## ۶.۴ راهکار شناختی: Divide and Conquer و Chunking

یک راه کاهش بار شناختی، تقسیم مسئله به زیرمسئله‌هاست. در agentهای Long-Horizon، هر sub-goal می‌تواند مثل یک memory chunk عمل کند. پس از انجام sub-goal، لازم نیست همه جزئیات آن در حافظه بماند؛ فقط نتیجه مهم نگه داشته می‌شود.

مثلاً در Blocks World:

۱. بلوک آبی clear شود.
۲. بلوک نارنجی clear شود.
۳. بلوک آبی روی بلوک نارنجی قرار بگیرد.

فرمول کلی divide and conquer:

$$T(n) = aT(n/b) + f(n)$$

در برخی مسائل، تقسیم می‌تواند هزینه را از مرتبه‌های سنگین‌تر به حدود  $O(n \log n)$  کاهش دهد، اما این یک نتیجه کلی برای همه taskها نیست. اگر مسئله ساختار تقسیم‌پذیر نداشته باشد، chunking لزوماً کمک نمی‌کند؛ مانند برخی نسخه‌های ساده Gripper Robot.

تفاوت مهم انسان و مدل این است که انسان اغلب خودش تشخیص می‌دهد چه زمانی chunk بسازد، چه چیزی را فراموش کند و چه نتیجه‌ای را نگه دارد. در agentهای فعلی، معمولاً طراح باید sub-goalها، واحدهای حافظه‌ای و سیاست فراموشی را مشخص کند. بنابراین ایده شناختی مفید است، اما هنوز نیاز به طراحی محاسباتی دقیق دارد.



## فصل ۵

# ترنسفورمر، توجه و حافظه کاری

## ۱.۵ حافظه در Transformer

در یک Transformer:

- دانش بلندمدت در وزن هاست.
  - پردازش ورودی فعلی در لایه‌های attention و feed-forward رخ می‌دهد.
  - Self-Attention هر token را با token‌های دیگر مقایسه می‌کند و embedding آن را contextual می‌سازد.
- در کلاس ابتدا سه خانواده کلی Transformer مرور شد: encoder-only، decoder-only و encoder-decoder. برای بحث حافظه کاری، تمرکز بیشتر روی این ایده بود که مدل در زمان inference با ورودی فعلی چه می‌کند. وزن‌های مدل مثل حافظه بلندمدت‌اند؛ اما prompt یا ورودی جاری، چیزی است که باید در لحظه پردازش شود. به همین دلیل attention layer یکی از جاهای مهم برای تحلیل حافظه کاری مدل است.

## ۲.۵ Contextual Embedding

کلمه «شیر» در «شیر جنگل»، «شیر خوردنی» و «شیر آب» یک embedding ثابت نباید داشته باشد. Transformer با attention، embedding اولیه را به embedding وابسته به context تبدیل می‌کند. همین کار برای مسائلی مثل رفع ابهام معنای واژه (Word Sense Disambiguation) و حل ارجاع (Coreference Resolution) ضروری است.

در ابتدا هر token یک بازنمایی اولیه دارد که از وزن‌های آموزش دیده می‌آید. اما این بازنمایی هنوز نمی‌داند کلمه در جمله فعلی چه نقشی دارد. مثلاً در «علی رفت مدرسه. او کتابش را برداشت.» مدل باید بفهمد «او» به «علی» برمی‌گردد. بنابراین embedding «او» باید با توجه به context به بازنمایی «علی» نزدیک‌تر شود. این تغییر همان کاری است که حافظه کاری مدل روی ورودی فعلی انجام می‌دهد.

### ۳.۵ Query, Key, Value

برای هر token سه بردار ساخته می‌شود:

$$Q = xW_Q, \quad K = xW_K, \quad V = xW_V$$

سپس وزن توجه به صورت ساده از ضرب  $QK^T$  و نرمال‌سازی به دست می‌آید و روی  $V$  اعمال می‌شود:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

تعبیر شهودی این است: Query می‌پرسد «من برای فهم خودم دنبال چه اطلاعاتی هستم؟»، Key می‌گوید «هر token چه نوع اطلاعاتی برای ارائه دارد؟» و Value همان محتوایی است که پس از تعیین وزن‌ها وارد بازنمایی جدید می‌شود. اگر Query یک token با Key دیگری سازگار باشد، وزن توجه بین آن‌ها بیشتر می‌شود. نتیجه این است که هر token فقط خودش نیست؛ نسخه جدید آن شامل اطلاعاتی از token‌های مرتبط در همان context است.

### ۴.۵ آیا کافی است attention را بزرگ‌تر کنیم؟

هدف همیشه افزایش طول context یا بزرگ‌تر کردن attention نیست. انسان هم فقط با بزرگ‌تر شدن حافظه بهتر نمی‌شود؛ بلکه با راهبردهایی مثل chunking، انتخاب و سازمان‌دهی بهتر عمل می‌کند. در مدل‌ها نیز مسئله اصلی این است که اطلاعات مرتبط بهتر بازیابی شود و اطلاعات نامرتب کمتر مزاحمت ایجاد کند.

یک ایده ساده این است که attention score‌های کوچک‌تر از یک آستانه حذف شوند، اما این کار همیشه درست نیست. attention نسبی است: یک ارتباط ممکن است نسبت به یک token ضعیف باشد، اما در زنجیره روابط نقش غیرمستقیم مهمی داشته باشد. برای مثال اگر  $A$  به  $B$  و  $B$  به  $C$  مرتبط باشد، حذف ساده ارتباط‌های ظاهراً کم‌وزن می‌تواند رابطه دوربرد  $A$  و  $C$  را خراب کند.

### ۵.۵ Local Attention

Local Attention محاسبه attention را به پنجره‌های محلی محدود می‌کند. مزیت آن کاهش هزینه محاسباتی و فشار حافظه‌ای است. خطر آن از دست رفتن وابستگی‌های دوربرد است. بنابراین معمولاً باید راهی برای ترکیب اطلاعات محلی در لایه‌های بالاتر وجود داشته باشد.

Local Attention به معنی حذف کامل بخش‌های متن نیست؛ بیشتر شبیه نگاه مرحله‌ای است. مدل در هر پنجره یک representation محلی می‌سازد و سپس باید این بازنمایی‌های محلی را در لایه یا مرحله‌ای بالاتر ترکیب کند. این ایده به divide and conquer شباهت دارد، اما فقط وقتی مفید است که ترکیب سطح بالاتر اطلاعات مهم دوربرد را دوباره در دسترس قرار دهد.

## ۶.۵ Mixture of Experts و Multi-Head Attention

Multi-Head Attention را می‌توان نگاه از چند زاویه دانست: یک head ممکن است روابط نحوی را ببیند، دیگری روابط معنایی یا ارجاعی را. Mixture of Experts نیز با فعال کردن متخصص‌های متفاوت، ظرفیت مدل را بهتر استفاده می‌کند. این‌ها مستقیماً معادل حافظه کاری نیستند، اما می‌توانند پردازش context را غنی‌تر کنند.

بنابراین در این بخش باید بین دو ادعا فرق گذاشت: این سازوکارها می‌توانند به استفاده بهتر از اطلاعات کمک کنند، اما خودشان پاسخ کامل به مسئله محدودیت حافظه کاری نیستند. اگر مدل نداند چه اطلاعاتی را نگه دارد، چه چیزی را خلاصه کند و چه چیزی را کنار بگذارد، صرف داشتن headهای بیشتر یا متخصص‌های بیشتر لزوماً مشکل بار شناختی را حل نمی‌کند.



## فصل ۶

# سوگیری شناختی و سه نظریه توضیح دهنده

### ۱.۶ تعریف Cognitive Bias

سوگیری شناختی (Cognitive Bias) یعنی سوگیری در فرایند تفکر، استدلال یا تصمیم‌گیری که باعث می‌شود فرد به نتیجه‌ای غلط یا غیربهبینه برسد. فرد معمولاً برای تصمیم خود دلیل می‌آورد، اما خود آن دلیل می‌تواند سوگیرانه باشد.

#### نکات اجرایی جلسه سوگیری

به دلیل عقب افتادن بعضی جلسات و محدودیت دسترسی به منابع آنلاین، استاد گفت ممکن است بخشی از جبران کلاس‌ها به صورت آنلاین یا آفلاین انجام شود، اما تأکید کرد این درس به بحث کلاسی نیاز دارد. همچنین اشاره شد پروژه اولیه به دلیل محدودیت اینترنت ممکن است تغییر کند یا بخشی از نمره با کار مطالعاتی/پروژه جایگزین پوشش داده شود.

### ۲.۶ انتخاب خط پژوهشی

در ابتدای جلسه سوگیری، استاد بحثی درباره انتخاب line of research در تحصیلات تکمیلی مطرح کرد. نکته اصلی این بود که دانشجو باید آگاهانه نسبت خود را با حوزه‌های حساس، کاربردی، درمانی، صنعتی یا دفاعی مشخص کند و فقط از روی محافظه‌کاری مسیر پژوهش را انتخاب نکند. این بخش محتوای فنی مستقیم نداشت، اما در چارچوب درس مهم بود چون پروژه پایانی باید به یک مسیر پژوهشی قابل دفاع و ادامه‌دار وصل شود.

## ۳.۶ نمونه‌ها

### ۱.۳.۶ Confirmation Bias

فرد باور قبلی دارد و اطلاعات جدید را طوری انتخاب یا تفسیر می‌کند که همان باور قبلی تأیید شود. مثال کلاس این بود که فرد از گذشته یک باور قوی دارد و هنگام خواندن خبر، کتاب یا داده جدید، بیشتر به شواهدی توجه می‌کند که همان باور را تقویت کنند. مشکل فقط «ندیدن» داده نیست؛ گاهی داده دیده می‌شود، اما طوری تفسیر می‌شود که مدل ذهنی قبلی تغییر نکند.

### ۲.۳.۶ Anchoring Bias

اولین داده یا برداشت اولیه وزن زیادی پیدا می‌کند و روی قضاوت‌های بعدی اثر می‌گذارد. به همین دلیل «اولین‌ها» در تصمیم‌گیری وزن زیادی دارند: اولین برداشت از یک فرد، اولین عددی که در مذاکره شنیده می‌شود، یا اولین توضیحی که درباره یک مسئله دریافت می‌کنیم. این وزن زیاد گاهی مفید است، چون تصمیم سریع را ممکن می‌کند، اما در مسائل پیچیده می‌تواند قضاوت‌های بعدی را به سمت همان نقطه اولیه بکشد.

### ۳.۳.۶ Halo Effect

یک ویژگی مثبت فرد به ویژگی‌های دیگر او تعمیم داده می‌شود؛ مثلاً ظاهر مرتب باعث می‌شود ناخودآگاه او را باهوش‌تر یا قابل‌اعتمادتر فرض کنیم. پدیده celebrity نیز تا حدی با همین سازوکار توضیح داده می‌شود: یک ویژگی برجسته یا جذاب باعث می‌شود مخاطب اعتبار فرد را به حوزه‌هایی تعمیم دهد که لزوماً در آن‌ها تخصصی ندارد.

## ۴.۶ آیا bias همیشه بد است؟

نه. بسیاری از biasها در تکامل باقی مانده‌اند چون تصمیم‌گیری سریع و کم‌هزینه را ممکن می‌کنند. مشکل وقتی رخ می‌دهد که تصمیم مهم، پیچیده یا پرپیامد باشد و پاسخ سریع و سوگیرانه جای تحلیل دقیق را بگیرد.

## ۵.۶ توضیح اول: Cognitive Load Theory

اگر ذهن نمی‌تواند همه decision tree را load کند، ناچار greedy عمل می‌کند: بخشی از اطلاعات را انتخاب می‌کند و با همان تصمیم می‌گیرد. این تصمیم ممکن است feasible باشد، اما optimal نباشد. راهکارهای کاهش bias از

این منظر:

- ساختارمند کردن اطلاعات
- chunking
- چک لیست
- تقسیم مسئله به بخش های کوچک تر
- مدیریت attention

این توضیح می گوید سوگیری الزاماً از بی منطقی کامل نمی آید؛ گاهی از محدودیت منابع پردازشی می آید. وقتی مسئله بزرگ است، فرد نمی تواند همه شاخه های ممکن را هم زمان نگه دارد، پس به یک راه حل محلی و کم هزینه تکیه می کند. این راه حل در شرایط روزمره ممکن است کافی باشد، اما در تصمیم های پرهزینه یا حساس باید ساختار مسئله را صریح تر کرد تا فشار حافظه کاری کمتر شود.

## ۶.۶ توضیح دوم: Dual Process Theory

طبق نظریه دوفرآیندی، انسان دو سبک پردازش دارد:

- سیستم ۱ (System 1): سریع، شهودی، کم هزینه و مناسب واکنش فوری.
- سیستم ۲ (System 2): کندتر، تحلیلی، مرحله به مرحله و پرهزینه تر.

سوگیری معمولاً وقتی رخ می دهد که مسئله به سیستم ۲ نیاز دارد اما سیستم ۱ پاسخ سریع می دهد و همان پاسخ اصلاح نمی شود.

سیستم ۱ همیشه بد نیست. در بسیاری از موقعیت های روزمره، واکنش سریع و شهودی لازم است و اگر قرار باشد برای هر تصمیم کوچک تحلیل عمیق انجام دهیم، هزینه زمانی و شناختی بیش از حد می شود. خطر وقتی بالا می رود که مسئله مهم، پیچیده، تازه یا پریامد است، اما ذهن همچنان با پاسخ سریع پیش فرض جلو می رود.

برای کاهش سوگیری از این منظر، باید عمداً شرایط فعال شدن سیستم ۲ را فراهم کرد: مکث قبل از تصمیم، نهایی نکردن اولین پاسخ، تصمیم نگرفتن در خستگی یا فشار روانی، جمع کردن شواهد بیشتر، صریح کردن معیارهای تصمیم و نقد پاسخ اولیه.

## ۷.۶ رفتار شبیه سیستم ۲ در LLM

در LLM واقعاً سیستم ۱ و سیستم ۲ انسانی وجود ندارد، اما می توان خروجی مدل را به رفتار سریع یا تحلیلی نزدیک کرد. روش ها:

- درخواست reasoning مرحله به مرحله

- self-critique
- few-shot prompting با مثال‌های مرزی
- Chain of Thought
- Tree of Thought
- نقد پاسخ اولیه و بازنویسی پاسخ

برای نمونه، self-critique را می‌توان چنین دید: مدل ابتدا یک پاسخ اولیه می‌دهد، سپس از خودش می‌خواهد همان پاسخ را از نظر فرض‌ها، خطاها و شواهد بررسی کند، و بعد نسخه اصلاح‌شده را تولید کند. در Tree of Thought نیز مدل فقط یک مسیر استدلال را دنبال نمی‌کند؛ چند شاخه ممکن را بررسی می‌کند و سپس مسیر بهتر را انتخاب می‌کند. این روش‌ها دقیقاً سیستم ۲ انسانی نیستند، اما خروجی را از پاسخ سریع و تک‌مسیره دور می‌کنند.

## ۸.۶ توضیح سوم: Predictive Coding

طبق کدگذاری پیش‌بینانه (Predictive Coding)، مغز فقط گیرنده منفعل داده نیست؛ بلکه دائماً از بالا به پایین پیش‌بینی تولید می‌کند و ورودی حسی پایین‌به‌بالا را با آن مقایسه می‌کند.

$$\text{Prediction Error} = \text{Input} - \text{Prediction}$$

اگر خطا کوچک باشد، سیستم پایدار می‌ماند. اگر خطا بزرگ باشد، یا prior باید اصلاح شود یا input جدید جمع‌آوری شود.

## فصل ۷

# Predictive Coding، بیز و مدل‌های عصبی

## ۱.۷ Prior، Likelihood و Posterior

در زبان بیزی:

$$\text{Posterior} \propto \text{Prior} \times \text{Likelihood}$$

در این نگاهت:

- حافظه بلندمدت و باور قبلی شبیه Prior است.
- ورودی فعلی شبیه Likelihood است.
- باور به‌روزشده شبیه Posterior است.

مثال کارآگاه و صحنه جرم در کلاس برای همین نگاهت بود. کارآگاه با prior وارد صحنه می‌شود، اما شواهد صحنه نقش likelihood دارند. اگر شواهد معتبر و قوی باشند، باور اولیه باید جابه‌جا شود. اگر شواهد ضعیف، مبهم یا کم‌اعتبار باشند، باور قبلی وزن بیشتری پیدا می‌کند.

## ۲.۷ Precision

**Precision** (Precision) یعنی میزان اطمینان یا وزن یک منبع اطلاعاتی. اگر prior بر اساس تجربه طولانی و شواهد زیاد شکل گرفته باشد، precision آن بالاست. اگر input واضح، معتبر و مستقیم باشد، precision input بالاست.

فرمول میانگین posterior:

$$\mu_{\text{posterior}} = \frac{\pi_p \mu_p + \pi_i \mu_i}{\pi_p + \pi_i}$$

که در آن  $\pi_p$  precision prior و  $\pi_i$  precision input است.

بازنویسی فرمول:

$$\mu_{\text{posterior}} = \mu_p + \frac{\pi_i}{\pi_p + \pi_i} (\mu_i - \mu_p)$$

عبارت  $(\mu_i - \mu_p)$  همان prediction error است و ضریب قبل از آن وزن خطاست.

### ۳.۷ چه زمانی belief update نمی‌شود؟

- وقتی prediction error صفر باشد.
- وقتی precision input بسیار کم باشد.
- وقتی precision prior بسیار بیشتر از precision input باشد.

حالت سوم توضیح خوبی برای confirmation bias است: prior آن قدر قوی است که شواهد جدید نمی‌توانند آن را جابه‌جا کنند.

مثال رسانه و تخصص نیز همین را نشان می‌دهد. فردی که درباره یک موضوع تخصص و تجربه بلندمدت دارد، -precision prior بالایی دارد و با هر خبر ضعیفی نظرش عوض نمی‌شود. این همیشه بد نیست. مشکل وقتی رخ می‌دهد که prior قوی ولی غلط باشد، یا فرد عمداً precision input مخالف را نزدیک صفر فرض کند.

### ۴.۷ وقتی خطا وجود دارد، سیستم چه می‌کند؟

اگر prediction error معنی‌دار باشد، دو مسیر کلی داریم:

- اصلاح prior: باور قبلی عوض می‌شود تا با شواهد سازگارتر شود.
  - جمع‌آوری یا تغییر input: فرد داده جدید می‌گیرد، زاویه نگاه را عوض می‌کند یا محیط را بهتر اندازه‌گیری می‌کند.
- اگر هیچ‌کدام انجام نشود، سیستم ممکن است خطا را با توجیه، نادیده گرفتن یا بازتفسیر شواهد حل کند. این همان نقطه‌ای است که predictive coding می‌تواند به توضیح سوگیری شناختی کمک کند.

### ۵.۷ کاهش bias در LLM با این چارچوب

اگر وزن‌های مدل را prior بدانیم، برای کاهش تکیه بیش از حد بر prior عمومی مدل می‌توان precision input را بالا برد یا precision prior نامطلوب را کم کرد:

- RAG: دادن شواهد بیرونی معتبر و مرتبط.
- Few-shot prompting: روشن کردن الگوی مطلوب با نمونه‌های مشخص.
- Negative prompting: محدود کردن فرض‌ها یا سوگیری‌های ناخواسته.
- Role playing: هدایت مدل به نقش دقیق‌تر، مثل «داور بی طرف».

## ۶.۷ تفاوت با شبکه‌های عصبی رایج

در شبکه عصبی رایج، معمولاً خطا در خروجی نهایی محاسبه می‌شود و با Backpropagation به کل شبکه برمی‌گردد. این خطا global و end-to-end است. در Predictive Coding، ایده این است که خطا به صورت local و پیوسته در سطوح مختلف محاسبه شود.

تفاوت دوم جریان اطلاعات است:

- شبکه‌های رایج عمدتاً bottom-up هستند.
- predictive coding هم bottom-up و هم top-down دارد.

## ۷.۷ آیا GAN شبیه Predictive Coding است؟

شباهت استعاری وجود دارد: در GAN یک generator تولید می‌کند و discriminator ارزیابی می‌کند؛ در predictive coding نیز سیستم پیش‌بینی تولید می‌کند و با input مقایسه می‌کند. اما نداشتن دقیق نیست. در predictive coding، خطای محلی و جریان پیوسته top-down/bottom-up نقش مرکزی دارد؛ در GAN خطا و یادگیری در چارچوب adversarial و معمولاً با backpropagation انجام می‌شود.

## ۸.۷ پردازنده‌های Neuromorphic

در اکوسیستم رایج هوش مصنوعی، بیشتر مدل‌ها روی GPU و با backpropagation آموزش یا اجرا می‌شوند. در مقابل، پردازنده‌های نورومورفیک (Neuromorphic) می‌کوشند از ایده‌های مغز الهام بگیرند: نرون، spike، سیناپس، پردازش محلی و گاهی یادگیری رویدادمحور. این سخت‌افزارها هنوز جایگزین عمومی GPU نشده‌اند، چون اکوسیستم نرم‌افزاری و شتاب‌دهنده‌های فعلی حول GPU شکل گرفته است. برای استفاده وسیع، مزیت عملی آن‌ها باید در هزینه، انرژی، تأخیر یا نوع پردازش به‌روشنی نشان داده شود.

### تمرین و ارزیابی مربوط به Predictive Coding

استاد اشاره کرد احتمالاً تمرینی درباره Predictive Coding در سامانه درس قرار می‌گیرد. همچنین با توجه به شرایط، ارزیابی ممکن است بیشتر به سمت امتحان کتبی مفهومی برود؛ یعنی توضیح مفاهیم، رسم معماری‌ها و تحلیل سناریوها.



## فصل ۸

### توجه انتخابی

#### ۱.۸ حافظه حسی و گلوگاه توجه

محیط حجم عظیمی از اطلاعات تولید می‌کند. حواس ما بخش زیادی از آن را در حافظه حسی (Sensory Memory) ثبت می‌کنند، اما این اطلاعات فقط برای زمان کوتاه باقی می‌ماند. همه آن‌ها نمی‌توانند وارد حافظه کاری شوند. بنابراین باید انتخاب کنیم. این انتخاب همان توجه انتخابی (Selective Attention) است.

مسیر کلی:

عمل → حافظه کاری → توجه انتخابی → حافظه حسی → محیط

نکته اصلی این است که حافظه حسی ظرفیت نسبتاً زیادی دارد، اما ماندگاری آن کوتاه است. وقتی وارد یک محیط می‌شویم، صداها، تصویرها، بوها و حس‌های بدنی زیادی هم‌زمان ثبت می‌شوند. با این حال، فقط بخشی از آن‌ها از گلوگاه توجه عبور می‌کند و وارد پردازش آگاهانه یا حافظه کاری می‌شود. مسئله نظریه‌های توجه این است که این انتخاب در کجای مسیر و بر اساس چه چیزی انجام می‌شود.

این بحث با attention در Transformer یکی نیست. در مدل زبانی، معمولاً prompt از قبل محیط مدل را تعیین کرده است. اما در سیستم‌هایی که واقعاً در محیط فیزیکی اند، مثل دستیار صوتی، دوربین یا ربات، سیستم باید از میان سیگنال‌های بیرونی تشخیص دهد کدام بخش اصلاً ارزش پردازش عمیق دارد.

#### ۲.۸ Broadbent's Filter Theory: انتخاب زودهنگام

در انتخاب زودهنگام (Early Selection)، فیلتر قبل از درک معنا عمل می‌کند. ورودی‌ها بر اساس ویژگی‌های فیزیکی یا آکوستیکی مثل شدت، جهت، آشنایی صدا یا نزدیکی انتخاب می‌شوند. سپس فقط ورودی انتخاب‌شده وارد پردازش معنایی می‌شود.

این نظریه توضیح می‌دهد چرا در یک مهمانی می‌توانیم روی صدای یک نفر تمرکز کنیم و بسیاری از صداها را نفهمیم.

مسیر ساده Early Selection چنین است:

Multiple Inputs → Physical Filter → Semantic Processing

برای مثال، در مهمانی ممکن است صدای دوست روبه‌روی خود را انتخاب کنیم چون نزدیک‌تر است، جهت صدا مشخص است یا صدایش برای ما آشناست. در این دیدگاه، ابتدا کانال صوتی انتخاب می‌شود و سپس معنای همان کانال پردازش می‌شود.

محدودیت نظریه این است که گاهی اطلاعات ظاهراً انتخاب نشده هم اثر می‌گذارند. اگر مشغول صحبت با کسی باشیم اما فرد دیگری در گوشه اتاق اسم ما را صدا بزند، ممکن است ناگهان متوجه شویم. اگر پیام‌های دیگر کاملاً حذف شده باشند، توضیح این پدیده دشوار می‌شود.

## ۳.۸ Late Selection

در انتخاب دیر هنگام (Late Selection)، ذهن ابتدا ورودی‌ها را تا حدی از نظر معنا پردازش می‌کند و سپس انتخاب می‌کند کدام ورودی مهم‌تر است. این نظریه پدیده‌ای مثل شنیدن اسم خود در یک مهمانی شلوغ را بهتر توضیح می‌دهد. مشکل این دیدگاه آن است که پردازش معنایی همه ورودی‌ها هزینه بسیار زیادی دارد. Late Selection، فیلتر پس از پردازش معنایی نسبی قرار دارد:

Multiple Inputs → Semantic Processing → Selection

پس اگر اسم خودمان در کانالی غیر از مکالمه اصلی شنیده شود، چون معنای آن برای ما مهم است، می‌تواند انتخاب شود. اما اگر این نظریه را خیلی قوی بگیریم، باید بپذیریم مغز تقریباً همه ورودی‌ها را از نظر معنا پردازش می‌کند؛ چیزی که با محدودیت انرژی و تجربه روزمره سازگار نیست.

## ۴.۸ Perceptual Load Theory

نظریه بار ادراکی (Perceptual Load Theory) می‌گوید هر دو حالت وجود دارند و بسته به بار ادراکی task فعال می‌شوند.

- بار ادراکی بالا: early selection غالب است.
- بار ادراکی پایین: late selection امکان‌پذیرتر است.

مثلاً رانندگی در جاده ناآشنا و شب، بار ادراکی بالایی دارد و مکالمه اطراف را کمتر پردازش می‌کنیم. اما در مسیر آشنا و ساده، ظرفیت بیشتری برای پردازش ورودی‌های دیگر داریم.

بنابراین اختلاف Early Selection و Late Selection را نباید فقط به شکل «کدام نظریه درست است؟» دید. پاسخ بهتر این است که سیستم توجه انسان انعطاف‌پذیر است. وقتی کار سخت، تازه، خطرناک یا پر جزئیات است، ذهن زودتر فیلتر می‌کند. وقتی کار ساده، تکراری یا آشناست، ظرفیت بیشتری برای پردازش معنایی ورودی‌های جانبی باقی می‌ماند.

## ۵.۸ Treisman's Attenuation Theory

در نظریهٔ تضعیف (Attenuation)، فیلتر صفر و یکی نیست. اطلاعات حذف کامل نمی‌شوند؛ برخی تقویت و برخی تضعیف می‌شوند. محرک‌هایی با آستانه (Threshold) پایین، مثل اسم خود فرد، حتی اگر تضعیف باشند می‌توانند فعال شوند.

این ایده برای سیستم‌های صوتی نیز مهم است: wake word مثل «Hey Siri» یا «Alexa» برای سیستم آستانهٔ پایینی دارد.

در این نظریه، فیلتر مثل دروازه‌ای نیست که بعضی پیام‌ها را کامل عبور دهد و بقیه را کامل حذف کند. بهتر است آن را مثل تنظیم‌کنندهٔ شدت ببینیم: پیام اصلی تقویت می‌شود، پیام‌های دیگر تضعیف می‌شوند، اما اگر محرکی اهمیت یا آشنایی زیادی داشته باشد، با وجود تضعیف می‌تواند از آستانه عبور کند. اسم خود فرد یا wake word دقیقاً چنین جایگاهی دارد.

## ۶.۸ پردازش سری و موازی

بسیاری از کارهای ساده می‌توانند هم‌زمان انجام شوند، اما کارهای پیچیده‌ای مثل دو محاسبهٔ دشوار معمولاً واقعاً موازی انجام نمی‌شوند؛ ما بیشتر بین آن‌ها task switching می‌کنیم. بنابراین توجه به یک گلوگاه نیاز دارد که تعیین کند کدام ورودی در هر لحظه پردازش عمیق‌تر شود.

مثال کلاس این بود که اگر از فرد بخواهیم هم‌زمان دو ضرب دشوار انجام دهد، معمولاً واقعاً هر دورا موازی حل نمی‌کند؛ بلکه سریع بین آن‌ها جابه‌جا می‌شود. کارهای ساده‌تر ممکن است هم‌زمان به نظر برسند، اما پردازش‌هایی که نیازمند معنا، تصمیم یا محاسبه‌اند معمولاً به انتخاب و ترتیب نیاز دارند. همین نیاز، اهمیت توجه انتخابی را در معماری شناختی نشان می‌دهد.



## فصل ۹

# پردازش گفتار و نگاشت توجه انتخابی به ماشین

## ۱.۹ دستیار صوتی و Wake Word

یک دستیار صوتی همیشه در محیط واقعی قرار دارد. اگر بخواهد همه صداها را دائماً به متن تبدیل کند و معنای همه را بفهمد، هزینه محاسباتی و انرژی بسیار زیاد می‌شود. بنابراین معمولاً دو مرحله دارد:

- مرحله **Early Selection**: تشخیص wake word با پردازش سبک آکوستیکی.
- مرحله **Late Selection**: پس از فعال شدن، تبدیل گفتار به متن، NLU، تشخیص intent و slot filling.

مثال:

Speech → Wake Word Detection → ASR → NLU → Action

## ۲.۹ تولید گفتار انسان

گفتار از تعامل دیافراگم، ریه، نای، حنجره، تارهای صوتی، زبان، دهان، بینی، فک و دندان‌ها تولید می‌شود. موج صوتی علاوه بر محتوای زبانی، اطلاعاتی درباره هویت گوینده، جنسیت، لهجه، احساسات و ویژگی‌های فیزیکی مجرای صوتی دارد.

در فارسی معمولاً شش واژه اصلی داریم: سه واژه کوتاه و سه واژه بلند. تعداد واژه‌ها در زبان‌هایی مثل انگلیسی بیشتر و وابسته به لهجه است.

## ۳.۹ از موج خام تا ویژگی

### ۱.۳.۹ Raw Wave

موج صوتی خام را می‌توان روی دو محور دید: زمان و دامنه. دامنه بزرگ‌تر معمولاً صدای بلندتر را نشان می‌دهد و سرعت نوسان موج با فرکانس مرتبط است. ماشین با موج آنالوگ کار نمی‌کند؛ بنابراین موج باید به دنباله‌ای از عددها تبدیل شود تا بتوان آن را به مدل داد.

### ۲.۳.۹ Sampling

ماشین با موج آنالوگ کار نمی‌کند؛ باید سیگنال نمونه‌برداری و دیجیتال شود. طبق قضیه Nyquist، نرخ نمونه‌برداری باید دست‌کم دو برابر بیشترین فرکانس موردنظر باشد.

### ۳.۳.۹ Windowing و Framing

سیگنال صوتی به frame‌های کوتاه تقسیم می‌شود. معمولاً frame‌ها هم‌پوشانی دارند تا تغییرات مهم در مرز frame‌ها از دست نرود. Hamming Window به مرکز frame وزن بیشتر و به لبه‌ها وزن کمتر می‌دهد.

### ۴.۳.۹ Spectrogram و Fourier Transform

تبدیل فوریه نشان می‌دهد چه فرکانس‌هایی در سیگنال حضور دارند. با اعمال این تبدیل روی frame‌های کوتاه، تصویری به نام اسپکتروگرام (Spectrogram) ساخته می‌شود. اسپکتروگرام تغییرات انرژی فرکانسی را در طول زمان نشان می‌دهد.

در اسپکتروگرام، یک محور زمان، محور دیگر فرکانس و رنگ یا شدت تصویر انرژی هر فرکانس را نشان می‌دهد. گفتار، تنفس و نویز معمولاً الگوهای متفاوتی در اسپکتروگرام دارند؛ به همین دلیل حتی پیش از تبدیل گفتار به متن می‌توان برخی طبقه‌بندی‌های آکوستیکی را انجام داد.

### ۵.۳.۹ Formants

فورمنت (Formant) ناحیه‌ای از انرژی فرکانسی قوی در گفتار است. فورمنت‌ها با محدوده فرکانسی نام‌گذاری می‌شوند، نه صرفاً بر اساس اولین نوار قابل مشاهده. بنابراین اگر باند پایین دیده نشود، نوار بالاتر الزاماً F1 نیست.

فورمنت‌ها با شکل مجرای صوتی و کیفیت واکه‌ها مرتبط‌اند و از pitch یا فرکانس پایه جدا هستند. به طور کلی صدای مردان معمولاً انرژی بیشتری در فرکانس‌های پایین‌تر دارد و صدای زنان معمولاً زیرتر است، اما تشخیص گوینده یا جنسیت را نباید فقط به یک باند ساده فروکاست؛ لهجه، سن، میکروفون و شرایط ضبط نیز اثر دارند.

## MFCC ۴.۹

ضرایب کپسترال فرکانس مل (Mel-Frequency Cepstral Coefficients / MFCC) نمایش عددی مفیدی از صوت است. مسیر کلی:

Waveform → Frames → Window → Fourier → Mel Filter Bank → MFCC

Mel Filter Bank با حساسیت شنوایی انسان سازگارتر است: در فرکانس‌های پایین تفکیک بیشتری نگه می‌دارد و در فرکانس‌های بالا رزولوشن کمتر می‌شود. فیلترهای مل معمولاً مثلثی و هم‌پوشان‌اند. در محاسبه رایج MFCC، پس از انرژی‌های mel، لگاریتم و سپس DCT اعمال می‌شود تا ضرایب فشرده‌تر و مناسب‌تری برای مدل‌های کلاسیک به دست آید.

## ۵.۹ کاربرد در طبقه‌بندی

برای تشخیص wake word یا حتی طبقه‌بندی‌هایی مثل تشخیص الگوهای سرفه، می‌توان از MFCC یا spectrogram ویژگی استخراج کرد و سپس با معیارهایی مثل correlation, similarity یا یک classifier بررسی کرد آیا دو گروه قابل تفکیک‌اند یا نه.

در مثال پزشکی کلاس، اگر بخواهیم از صدای سرفه یا تنفس افراد مبتلا و غیرمبتلا ویژگی بگیریم، ابتدا باید نشان دهیم featureها واقعاً تفاوت قابل اتکا دارند. اگر همبستگی یا شباهت دو گروه بسیار بالا باشد، classifier احتمالاً اطلاعات کافی برای تفکیک ندارد. بنابراین استخراج ویژگی فقط گام اول است؛ اعتبار ویژگی باید با داده و ارزیابی روشن شود.

### تمرین Early Selection

یکی از تمرین‌های اعلام‌شده: یک فایل صوتی کوتاه شامل اسم خود و یک wake-up phrase ضبط شود، یک فایل نویز محیطی تعریف شود و ویژگی‌های MFCC استخراج گردد. مهلت کلی تمرین‌های مطرح‌شده تا پایان اردیبهشت اعلام شد.



## فصل ۱۰

# مدل‌های گفتاری: wav2vec، HuBERT و Whisper

### ۱.۱۰ آیا همیشه باید گفتار به متن تبدیل شود؟

معماری رایج:

Speech → Text → NLP Task → Action

اما از نظر نظری همیشه لازم نیست متن میانی داشته باشیم. برای taskهای محدود می‌توان مستقیماً از waveform، MFCC، spectrogram یا embedding صوتی به intent یا class رسید. با این حال، متن مزیت دارد: داده آموزشی متنی فراوان‌تر است، اتصال به API و پایگاه داده ساده‌تر است و ambiguity برخی فرمان‌ها کمتر می‌شود.

در کلاس این پرسش مطرح شد که اگر هدف فقط فهم فرمان است، چرا اصلاً گفتار را به متن تبدیل کنیم؟ پاسخ این است که حذف متن ممکن است در مسئله‌های محدود مفید باشد، اما در سیستم عمومی معمولاً متن یک لایه میانی استاندارد و قابل اتصال می‌سازد. بسیاری از ابزارهای پایین‌دستی، پایگاه‌های داده، APIها و مدل‌های زبانی با متن راحت‌تر کار می‌کنند. علاوه بر آن، داده متنی برچسب‌دار بسیار بیشتر از صوت برچسب‌دار دقیق است.

### ۲.۱۰ سه جزء سیستم گفتاری

- تشخیص خودکار گفتار (ASR): تبدیل گفتار به متن.
- فهم زبان طبیعی (NLU): استخراج intent، slot و معنا از متن یا representation.
- تبدیل متن به گفتار (TTS): تولید پاسخ صوتی از متن.

## ۳.۱۰ ویژگی‌های learnable و deterministic

Spectrogram و MFCC معمولاً با فرمول‌های ریاضی deterministic تولید می‌شوند و مرحله آموزش ندارند. در مقابل، می‌توان waveform خام را به CNN داد تا featureها را یاد بگیرد:

Raw Waveform → CNN → Learned Features

در CNN، فیلترها یا kernelها پارامترهای قابل یادگیری‌اند. در لایه‌های اولیه، مدل معمولاً الگوهای محلی و ساده‌تر را می‌گیرد و در لایه‌های عمیق‌تر بازنمایی‌ها انتزاعی‌تر می‌شوند. Pooling می‌تواند بعد را کاهش دهد، اطلاعات برجسته را فشرده کند و هزینه محاسباتی را پایین بیاورد. در wav2vec، ورودی معمولاً waveform خام است؛ اشاره به spectrogram در کلاس بیشتر برای توضیح شهودی CNN بود.

## ۴.۱۰ Self-Supervised Learning در گفتار

داده صوتی خام زیاد است، اما صوت همراه با transcript دقیق کمتر است. مدل‌های self-supervised از خود داده task آموزشی می‌سازند؛ مثلاً بخشی از فریم‌ها را mask می‌کنند و مدل باید از context آن‌ها را پیش‌بینی کند یا representation مناسب بیاموزد.

## ۵.۱۰ wav2vec 2.0

مسیر کلی wav2vec 2.0:

Raw Waveform → CNN Feature Encoder → Transformer Encoder  
→ Contextual Representations

بخشی از representationهای نهفته mask می‌شود. سپس مدل با هدف contrastive یاد می‌گیرد representation درست را از نمونه‌های منفی جدا کند. Quantization با codebook کمک می‌کند هدف آموزشی گسسته‌تر و پایدارتر باشد.

## ۱.۵.۱۰ Quantization و Codebook

در صوت، برخلاف متن، vocabulary طبیعی و گسسته نداریم. Quantization یک بردار پیوسته را به نزدیک‌ترین بردار نماینده در codebook نگاشت می‌کند. این کار شبیه ساختن vocabulary صوتی است، اما نباید representation غنی مسیر اصلی را خیلی زود نابود کند. در wav2vec 2.0، quantized targets عمدتاً برای loss استفاده می‌شوند.

در هدف **contrastive**، مدل باید نمایش درست مربوط به بخش **masked** را به نمونه مثبت نزدیک و از نمونه‌های منفی دور کند. بنابراین **quantization** برای ساختن هدف آموزشی روشن‌تر به کار می‌رود، در حالی که **Transformer Encoder** همچنان روی بازنمایی‌های پیوسته و غنی کار می‌کند. بعد از **pretraining**، مدل می‌تواند با دادهٔ برچسب‌دار کمتر برای **ASR**، طبقه‌بندی یا کارهای گفتاری دیگر **fine-tune** شود.

مثال کلاس برای **codebook**، مکان‌یابی سلسله‌مراتبی بود: نخست کشور، بعد شهر، بعد منطقه. این مثال نشان می‌دهد یک فضای پیوسته را می‌توان در چند سطح به واحدهای گسسته‌تر و قابل مقایسه‌تر تبدیل کرد.

## HuBERT ۶.۱۰

**HuBERT** نیز از **masking** استفاده می‌کند، اما معمولاً هدف آن پیش‌بینی برچسب‌های خوشه‌ای پنهان‌شده است. این تفاوت نشان می‌دهد همهٔ مدل‌های **self-supervised** گفتاری یک **objective** واحد ندارند.

## Whisper ۷.۱۰

**Whisper** برخلاف **wav2vec** که بیشتر برای **pretraining representation** مطرح شد، مستقیماً صوت را به متن تولید می‌کند. دادهٔ آموزشی آن حدود ۶۸۰ هزار ساعت صوت-متن چندزبانه و پرتنوع است و به همین دلیل نسبت به لهجه، نویز و شرایط واقعی **robust** است.

## ۱.۷.۱۰ چرا Encoder-Decoder؟

مدل باید هم صوت را بفهمد و هم متن تولید کند. بنابراین معماری مناسب:

Audio Encoder → Text Decoder

در **Whisper** ورودی معمولاً **log-mel spectrogram** است. **Encoder** با **self-attention** کامل، **embedding** صوتی **contextualized** می‌سازد. **Decoder** به صورت **autoregressive** متن را تولید می‌کند.

دلیل نیاز به دو بخش این است که وظیفه فقط استخراج بازنمایی صوتی نیست. **Encoder** باید از ورودی صوتی یک بازنمایی قابل استفاده بسازد؛ اما خروجی نهایی دنباله‌ای از **tokens** متنی است و باید یکی‌یکی تولید شود. بنابراین بخش **Decoder** لازم است تا با توجه به متن تولیدشده تا آن لحظه و بازنمایی صوتی، **token** بعدی را پیش‌بینی کند.

## ۲.۷.۱۰ Cross-Attention و Masked Self-Attention

در **Encoder**، کل ورودی صوتی موجود است، پس **self-attention** ماسک ندارد. در **Decoder**، توکن‌های آینده نباید دیده شوند، پس **masked self-attention** لازم است. همچنین **Decoder** با **cross-attention** به خروجی **Encoder** توجه می‌کند تا متن تولیدشده با صوت اصلی هم‌راستا بماند.

Cross-Attention پل بین دو جهان است: Decoder در فضای متن کار می‌کند، اما برای اینکه متن تولیدی از صوت جدا نشود باید به خروجی Encoder نگاه کند. اگر این اتصال نباشد، Decoder فقط شبیه یک مدل زبانی عمل می‌کند و ممکن است متن روان ولی نامرتبط با صوت تولید کند.

## ۸.۱۰ ایده پژوهشی از توجه انتخابی

اگر بخواهیم دستیار صوتی شناختی‌تر بسازیم، می‌توانیم بار ادراکی محیط را تخمین بزنیم و بر اساس آن بین پردازش سبک و سنگین سوئیچ کنیم:

High Perceptual Load → Early Selection

Low Perceptual Load → Late Selection

این ایده trade-off مهندسی میان هزینه محاسباتی و دقت معنایی را به زبان شناختی توضیح می‌دهد.

## فصل ۱۱

# سیستم پاداش و یادگیری تقویتی

### ۱.۱۱ پاداش در مغز

پس از بحث مدل‌های شنیداری، کلاس وارد سیستم پاداش شد. در انسان، پاداش به صورت حس رضایت، لذت یا موفقیت تجربه می‌شود و با آزادسازی dopamine ارتباط دارد. دوپامین در ناحیه VTA (Ventral Tegmental Area) تولید می‌شود و در مسیرهای دوپامینرژیک اثر می‌گذارد.

یادگیری مبتنی بر پاداش را می‌توان با زنجیره ساده زیر فهمید: سیستم در یک وضعیت قرار دارد، عملی انجام می‌دهد، وضعیت تغییر می‌کند و این تغییر با پاداش، تنبیه یا بازخورد خنثی همراه می‌شود. پاداش نقش reinforcer دارد؛ یعنی احتمال تکرار رفتارهای مفید یا خوشایند را در آینده تغییر می‌دهد.

پاداش فقط به رخدادهای زیستی مثل غذا محدود نیست. موفقیت در یک کار، دریافت پیام مهم، یا دیدن نشانه‌ای که قبلاً با تجربه خوب همراه بوده نیز می‌تواند سیستم پاداش را فعال کند. نکته مهم کلاس این بود که دوپامین معمولاً با یک transition معنادار مرتبط است: تغییری در وضعیت که برای سیستم ارزش یا انتظار ایجاد می‌کند.

### ۲.۱۱ دو مسیر مهم

#### Mesolimbic Pathway ۱.۲.۱۱

از VTA به سمت سیستم limbic می‌رود و با رضایت، شرطی شدن، تقویت رفتار، میل به تکرار و اعتیاد مرتبط است. این مسیر به طور ساده می‌گوید: «این رفتار قبلاً خوب بوده؛ دوباره انجامش بده.»

برای مثال، اگر نوشیدن چای بعد از کار بارها تجربه خوشایندی ایجاد کرده باشد، نشانه‌های پایان کار می‌توانند میل به چای را فعال کنند. این مسیر کمک می‌کند رفتارهای پاداش‌دهنده تکرار شوند، اما همین سازوکار در عادت‌های ناسالم و اعتیاد نیز نقش دارد.

## ۲.۲.۱۱ Mesocortical Pathway

از VTA به Prefrontal Cortex می‌رود و با تصمیم‌گیری، تحلیل پیامدها، کنترل رفتار و ارزیابی بلندمدت مرتبط است. اگر mesolimbic نقش گاز داشته باشد، mesocortical تا حدی نقش تحلیل‌گر و ترمز را دارد. مثال کلاس کیک بود: مسیر پاداش ممکن است خوردن کیک را جذاب کند، اما بخش پیش‌پیشانی می‌تواند پیامدهای بلندمدت، رژیم، گرسنگی واقعی و ارزش انجام این عمل را بررسی کند. بنابراین سیستم پاداش فقط «لذت» نیست؛ با کنترل، ارزیابی و تصمیم‌گیری نیز تعامل دارد.

## ۳.۱۱ ارتباط با Reinforcement Learning

در یادگیری تقویتی (Reinforcement Learning) عامل در یک state قرار دارد، action انجام می‌دهد، به state جدید منتقل می‌شود و reward می‌گیرد:

$$s_t \xrightarrow{a_t} s_{t+1}, \quad r_t$$

یادگیری از طریق تعامل با محیط و feedback انجام می‌شود. این تفاوت اصلی آن با supervised learning است که در آن label مستقیم داریم، و با unsupervised learning که در آن مدل معمولاً ساختار داده را بدون action و reward یاد می‌گیرد.

### تفاوت سه نوع یادگیری

- Supervised Learning: ورودی و label داریم.
- Unsupervised Learning: label مستقیم نداریم و ساختار داده را پیدا می‌کنیم.
- Reinforcement Learning: عامل با محیط تعامل می‌کند و از پاداش یا تنبیه یاد می‌گیرد.

در Supervised Learning، مدل برای هر ورودی معمولاً پاسخ درست یا label دارد. در Unsupervised Learning، مدل بدون برچسب مستقیم، ساختار داده را پیدا می‌کند؛ مثلاً خوشه‌ها یا بازنمایی‌ها را یاد می‌گیرد. اما در Reinforcement Learning مسئله فقط نبودن برچسب نیست. عامل باید عمل کند، پیامد عمل خود را ببیند و از reward یاد بگیرد. بنابراین تجربه، ترتیب زمانی و تعامل با محیط بخش اصلی مسئله‌اند.

## فصل ۱۲

# پروژه، تمرین‌ها و جمع‌بندی مسیر پژوهشی

### ۱.۱۲ مسیر پژوهشی پیشنهادی درس

یکی از مسیرهای پژوهشی مهم این است:

۱. یک ضعف شناختی در مدل نشان دهیم.
  ۲. بررسی کنیم آیا خطای مدل با خطای انسان correlation دارد یا نه.
  ۳. آن ضعف را با یک نظریه شناختی توضیح دهیم.
  ۴. dataset یا آزمایش مناسب طراحی کنیم.
  ۵. مدل را با روش‌هایی مثل fine-tuning، prompting، RAG، تغییر معماری یا اضافه کردن ماژول شناختی بهبود دهیم.
  ۶. نشان دهیم بهبود فقط افزایش سطحی عملکرد نیست، بلکه از نظر شناختی معنا دارد.
- سطح ورود به معماری‌ها در کلاس عمداً بین دو حد نگه داشته شد: نه آنقدر شناختی که از هوش مصنوعی دور شود، و نه آنقدر فنی که درس به تکرار جزئیات CNN، Transformer یا contrastive learning تبدیل شود. هدف این بود که دانشجو بتواند نظریه شناختی را بشناسد، مدل محاسباتی متناظر را در سطح لازم بفهمد و از آن برای طراحی ایده پژوهشی استفاده کند.

### ۲.۱۲ نمونه‌های موضوع پروژه

- dataset شناختی برای مقایسه انسان و مدل در reasoning، حافظه، توجه یا زبان.
- مدل‌سازی cognitive load در LLM و طراحی prompt‌های پرنویز.
- بررسی chunking در task‌های long-horizon agent.

- کاهش bias در LLM با چارچوب predictive coding.
- طراحی سیستم wake-word detection با MFCC و نویز محیطی.
- مقایسه early/late selection در معماری دستیار صوتی.
- بررسی یا شبیه‌سازی مفهومی پردازنده‌های نورومورفیک (Neuromorphic).

### پروژه پایانی

- پروژه باید مرتبط با مباحث کلاس باشد.
- پروژه حداکثر دو نفره است.
- هر گروه باید proposal حدوداً یک صفحه‌ای ارائه دهد.
- استاد پس از بررسی ممکن است scope پروژه را اصلاح کند.
- زمان تحویل پروژه حدوداً پیش از امتحان و نزدیک به پیش از ۲۰ خرداد مطرح شد.
- اگر دانشجویی ایده نداشته باشد، استاد می‌تواند موضوع پیشنهاد دهد.
- یکی از موضوع‌های پیشنهادی، بررسی یا پیاده‌سازی مجازی یک پردازنده Neuromorphic بود.

### میان‌ترم و تمرین‌ها

- تا جلسه دهم، سه تمرین مطرح شده بود و مهلت کلی آن‌ها پایان اردیبهشت اعلام شد.
- تمرین چهارم قرار بود از بحث Reinforcement Learning اعلام شود.
- میان‌ترم از مباحث کلاس است و می‌تواند شامل توضیح مفاهیم، رسم معماری‌ها، حل مسئله یا تحلیل سناریو باشد.
- زمان پیشنهادی میان‌ترم حوالی هفته سوم اردیبهشت بود و قرار شد در گروه کلاس درباره تاریخ آن نظرسنجی شود.
- استاد گفت وضعیت ضبط آفلاین، دسترسی به proxy/VPN دانشگاه و گزینه‌های تاریخ میان‌ترم را در گروه پیگیری می‌کند.

### نکته پایانی درباره ساختار درس

استاد اشاره کرد این درس برای نخستین بار در دانشکده با این سیلابس ارائه می‌شود و هنوز ساختار دستیار آموزشی کاملاً تثبیت نشده است. از دانشجویان علاقه‌مند و فعال خواسته شد برای همکاری احتمالی به عنوان TA در ترم‌های آینده اعلام آمادگی کنند.

## ۳.۱۲ جمع‌بندی کل درس تا اینجا

درس از این ایده شروع شد که مدل‌های هوش مصنوعی، حتی مدل‌های بزرگ، هنوز در برخی مهارت‌های شناختی مانند استدلال عمیق، قیاس، توجه، حافظه کاری، سوگیری و تعامل با محیط ضعیف دارند. راه‌حل صرفاً بزرگ‌تر کردن مدل یا اضافه کردن داده نیست. باید بفهمیم انسان این مهارت‌ها را چگونه انجام می‌دهد و کدام نظریه شناختی می‌تواند الهام‌بخش یک مدل محاسباتی بهتر باشد.

مسیر طی شده در جلسات موجود چنین بود:

- تعریف علوم شناختی محاسباتی و نسبت آن با AI.
- نظریه‌های پردازش گفتار مانند Cohort و TRACE.
- معماری شناختی و ACT-R.
- حافظه کاری، حافظه بلندمدت، chunking و cognitive load.
- attention در Transformer و محدودیت‌های context.
- cognitive bias و نظریه‌های Dual Process، Cognitive Load و Predictive Coding.
- attention انتخابی و نظریه‌های Early Selection، Late Selection، Perceptual Load و Attenuation.
- پردازش گفتار، MFCC، مدل‌های self-supervised، wav2vec، HuBERT و Whisper.
- سیستم پاداش و ارتباط آن با Reinforcement Learning.



## واژه‌نامه کوتاه

| اصطلاح                 | معنا در این درس                                                  |
|------------------------|------------------------------------------------------------------|
| Cognitive Architecture | چارچوب یکپارچه ماژول‌های شناختی مانند حافظه، ادراک و عمل         |
| Working Memory         | حافظه فعال و محدود برای پردازش فعلی                              |
| Declarative Memory     | دانش صریح و factها                                               |
| Procedural Memory      | مهارت‌ها و روندهای انجام کار                                     |
| Chunking               | تبدیل چند جزء به یک واحد معنادار برای کاهش بار حافظه             |
| Predictive Coding      | مدل کردن مغز به عنوان سیستم پیش‌بین و محاسبه‌کننده خطای پیش‌بینی |
| Precision              | وزن یا اطمینان نسبت به prior یا input                            |
| Early Selection        | انتخاب ورودی پیش از پردازش معنایی عمیق                           |
| Late Selection         | انتخاب ورودی پس از پردازش معنایی نسبی                            |
| MFCC                   | ویژگی عددی صوت بر اساس مقیاس ادراکی مل                           |
| ASR                    | تبدیل گفتار به متن                                               |
| NLU                    | فهم زبان طبیعی و استخراج intent/slot                             |
| Reinforcement Learning | یادگیری از تعامل با محیط و پاداش                                 |



# منابع کلاسیک و فنی برای پیگیری

این فهرست برای مطالعه بیشتر است و جایگزین فایل‌ها و مقاله‌های رسمی درس نیست:

- Miller, G. A. (1956). The Magical Number Seven, Plus or Minus Two.
- Broadbent, D. E. (1958). Perception and Communication.
- Deutsch & Deutsch (1963). Attention: Some theoretical considerations.
- Treisman (1964). Monitoring and storage of irrelevant messages.
- Lavie (1995). Perceptual load as a necessary condition for selective attention.
- Marslen-Wilson (1987). Functional parallelism in spoken word-recognition.
- McClelland & Elman (1986). The TRACE model of speech perception.
- Anderson, J. R. و آثار مربوط به ACT و ACT-R.
- Baevski et al. (2020). wav2vec 2.0.
- Hsu et al. (2021). HuBERT.
- Radford et al. (2022). Whisper.