

خلاصه امتحانی فصل ۵

پاداش، یادگیری تقویتی و تصمیم‌گیری
مرور تفکیک‌شده مفاهیم، فهرست‌ها و فرمول‌ها

بخش اول: سیستم پاداش و یادگیری تقویتی

۱.۱ مفاهیم پایه تعامل با محیط

- عامل (Agent)، وضعیت (State)، عمل (Action) و گذار (Transition): عامل در یک وضعیت قرار دارد، عملی انجام می‌دهد و از طریق گذار به وضعیت بعدی می‌رود:

$$S \xrightarrow{A} S'$$

- تقویت‌کننده (Reinforcer): پاداش یا تنبیهی که باعث یادگیری، تکرار یا کاهش یک رفتار می‌شود.
- ماژول ارزش‌گذاری (Utility Module): کیفیت عمل انجام‌شده را بررسی می‌کند تا مدل قبلی یا Prior Model به‌روزرسانی شود.


۲.۱ مراحل معماری شناختی در مواجهه با محرک

- دریافت محرک‌های حسی از طریق ماژول‌های بینایی یا شنیداری.
- انتخاب بخشی از اطلاعات محیط با فرایند توجه انتخابی.
- ورود اطلاعات فعلی به حافظه کوتاه‌مدت.
- بازیابی اطلاعات مرتبط از حافظه بلندمدت.
- ترکیب اطلاعات فعلی و دانش قبلی برای استخراج الگو.
- انتخاب عمل و اجرای آن از مسیر ماژول حرکتی.
- دریافت پاداش یا تنبیه در وضعیت بعدی و اصلاح مدل قبلی.

۳.۱ پاداش در مغز و دوپامین

- دوپامین (Dopamine): در واکنش به یک تغییر حالت معنادار و مهم ترشح می‌شود؛ بنابراین صرفاً نشانه «لذت» نیست.
- هر تجربه خوب الزاماً دوپامین زیادی ایجاد نمی‌کند؛ اگر تجربه کاملاً قابل پیش‌بینی باشد، غافلگیری و پاسخ دوپامینی کمتر است.
- ناحیه تگمنتوم شکمی (Ventral Tegmental Area; VTA): ناحیه مهم تولید دوپامین و محاسبه خطای پیش‌بینی پاداش.

۴.۱ مسیرهای دوپامینرژیک مرتبط با VTA



- مسیر مزولیمبیک (Mesolimbic Pathway):
 - مسیر: VTA به سیستم لیمبیک، به ویژه Nucleus Accumbens.
 - مسئول احساس رضایت، شرطی شدن، تقویت رفتار، اعتیاد و میل به تکرار رفتار.
 - ارزش محرک یا عمل را در حافظه بلندمدت تقویت یا تضعیف می‌کند.
 - استعاره: گاز؛ «این رفتار قبلاً خوب بوده است، دوباره انجامش بده.»
- مسیر مزوکورتیکال (Mesocortical Pathway):

- مسیر: VTA به قشر پیش‌پیشانی یا Prefrontal Cortex.
- مسئول تصمیم‌گیری، تحلیل، کنترل رفتار و ارزیابی پیامدهای بلندمدت.
- پاداش فوری را در برابر هزینه و نتیجه آینده بررسی می‌کند.
- استعاره: ترمز یا تحلیل‌گر.

۵.۱ اختلال‌ها و پدیده‌های مرتبط با سیستم پاداش

• پیری:

- تجربه بیشتر $\Leftarrow$ پیش‌بینی‌پذیری بیشتر محرک‌ها.
- نزدیک شدن خطای پیش‌بینی به صفر و کاهش ترشح دوپامین.
- کاهش به‌روزرسانی مدل و میل به تجربه چیزهای تازه یا Exploration.
- تجربه‌های تازه و کمتر تجربه‌شده می‌توانند غافلگیری سالم ایجاد کنند.

• افسردگی:

- سیستم پاداش به‌درستی فعال نمی‌شود و کارهای قبلاً لذت‌بخش جذابیت خود را از دست می‌دهند.
- فرد ممکن است با عمل نکردن و تجربه نکردن در حالت قطعیت باقی بماند.
- خطای نزدیک صفر در این حالت ناسالم است؛ زیرا از تجربه و دقیق‌تر شدن مدل حاصل نشده است.

• اعتیاد:

- تجربه اولیه می‌تواند خطای پیش‌بینی مثبت ایجاد کند:

$$RPE > 0$$

- با تکرار و سازگاری مغز، تجربه عادی می‌شود:

$$RPE \rightarrow 0$$

- فرد برای ایجاد غافلگیری مثبت دوباره، دوز را افزایش می‌دهد.
- مغز در واکنش دفاعی، حساسیت به دوپامین را کاهش می‌دهد؛ در نتیجه لذت از محرک اعتیادآور و محرک‌های عادی کمتر می‌شود.
- مقاومت در برابر این چرخه به میزان مواجهه، آگاهی، محیط، ژنتیک و قدرت مسیر مزوکورتیکال بستگی دارد.
- Marshmallow Test: نمونه‌ای از خودکنترلی، تأخیر پاداش و توجه به نتیجه بلندمدت.

چرخه اعتیاد

$$\dots \rightarrow RPE > 0 \rightarrow \text{افزایش دوز} \rightarrow RPE \approx 0 \rightarrow \text{سازگاری} \rightarrow RPE > 0 \rightarrow \text{تجربه قوی}$$

۶.۱ کدگذاری پیش‌بینانه

- کدگذاری پیش‌بینانه (Predictive Coding): مقایسه مداوم میان دانش قبلی یا Prior Knowledge و واقعیت مشاهده‌شده.
- مبنای یادگیری، خود واقعیت خام نیست؛ بلکه **خطای میان پیش‌بینی و واقعیت** است.
- در سیستم پاداش نیز انتظار قبلی با پاداش واقعی مقایسه می‌شود.

۷.۱ خطای پیش‌بینی پاداش

Error Prediction Reward

$$\text{Reward Prediction Error} = \text{Actual Reward} - \text{Predicted Reward}$$

$$RPE = R_{\text{actual}} - R_{\text{predicted}}$$

- $RPE > 0$: نتیجه بهتر از انتظار؛ غافلگیری مثبت و تقویت عمل یا محرک.
- $RPE = 0$: نتیجه مطابق انتظار؛ اطلاعات تازه‌ای برای تغییر مدل وجود ندارد.
- $RPE < 0$: نتیجه بدتر از انتظار؛ ارزش عمل یا محرک کاهش می‌یابد.

۸.۱ اصل انرژی آزاد

- اصل انرژی آزاد (Free Energy Principle): سیستم شناختی برای کاهش عدم قطعیت، غافلگیری و خطای پیش‌بینی محیط را تجربه می‌کند.
- هدف، هماهنگ‌شدن مدل ذهنی با واقعیت است:

$$RPE \rightarrow 0$$

- صفرشدن سالم خطا حاصل تجربه و اصلاح مدل است؛ نه عمل نکردن و تجربه نکردن.

بخش دوم: مدل‌های محاسباتی یادگیری تقویتی

۱.۲ یادگیری تقویتی و ویژگی‌های آن

- یادگیری تقویتی (Reinforcement Learning): یادگیری از طریق تعامل فعال با محیط، انجام عمل و دریافت پاداش یا تنبیه.
- یادگیری معمولاً برخط (Online) و نمونه‌به‌نمونه است؛ عامل از ابتدا مدل دقیق محیط را ندارد.
- در برابر یادگیری نظارت‌شده: برچسب درست یا Label آماده وجود ندارد.
- در برابر یادگیری بدون ناظر: هدف فقط کشف ساختار داده نیست؛ عمل و بازخورد پاداش بخش اصلی مسئله‌اند.

۲.۲ محیط قطعی و تصادفی

- محیط قطعی (Deterministic): یک عمل مشخص در یک وضعیت مشخص، همیشه به نتیجه یکسان می‌رسد.
- محیط تصادفی (Stochastic): انجام یک عمل مشخص لزوماً به یک نتیجه قطعی ختم نمی‌شود و گذار با احتمال همراه است:

$$S \xrightarrow{A} S'$$

- عامل باید با تجربه، دریافت بازخورد و اصلاح تدریجی مدل گذار با این عدم قطعیت کنار بیاید.

۳.۲ یادگیری تفاوت زمانی

- یادگیری تفاوت زمانی (Temporal Difference Learning): اختلاف میان ارزش پیش‌بینی شده در زمان t و نمونه حاصل از تجربه در زمان $t + 1$ را یاد می‌گیرد.
- نرخ یادگیری (Learning Rate) با α نشان داده می‌شود:

$$0 \leq \alpha \leq 1$$

- $\alpha = 0$: تجربه جدید اثری ندارد و یادگیری رخ نمی‌دهد.
- $\alpha = 1$: فقط تجربه جدید مهم است و دانش قبلی نادیده گرفته می‌شود.
- $0 < \alpha < 1$: درونیابی میان دانش قبلی و تجربه جدید.

فرمول به‌روزرسانی TD

$$V_{t+1} = V_t + \alpha(\text{Sample} - V_t)$$

$$\text{Sample} - V_t = RPE$$

$$V_{t+1} = V_t + \alpha \times \text{RPE}$$

- هدف نهایی:

$$\text{Sample} = V_t \implies \text{RPE} = \circ$$

۴.۲ ضریب تخفیف

- ضریب تخفیف (Discount Factor) با γ نشان داده می‌شود و میزان اهمیت پاداش‌های آینده را مدل می‌کند:

$$0 \leq \gamma \leq 1$$

- $\gamma = 0$: فقط پاداش فوری؛ تصمیم‌گیری کاملاً کوتاه‌نگر.
- $\gamma = 1$: پاداش‌های آینده بدون تخفیف در نظر گرفته می‌شوند.
- $0 < \gamma < 1$: آینده مهم است، اما پاداش‌های دورتر اثر کمتری دارند.

مجموع پاداش‌ها با ضریب تخفیف

$$r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 r_{t+3} + \dots$$

- ارتباط زیستی مطرح‌شده: سروتونین بالاتر ممکن است با عجله کمتر و توان بیشتر برای در نظر گرفتن پاداش آینده مرتبط باشد؛ البته رفتار به عوامل متعدد وابسته است.

۵.۲ تابع ارزش

- تابع ارزش (Value Function): ارزش قراردادن در حالت s را با $V(s)$ نشان می‌دهد.
- در هر گام، ارزش همان حالتی به‌روزرسانی می‌شود که عامل از آن حرکت کرده است.

فرمول کامل به‌روزرسانی تابع ارزش

$$V_{t+1}(s) = (1 - \alpha)V_t(s) + \alpha [r + \gamma V_t(s')]$$

- $V_t(s)$: ارزش قبلی حالت فعلی.
- r : پاداش دریافت‌شده.
- $V_t(s')$: ارزش حالت بعدی.
- $(1 - \alpha)V_t(s)$: سهم دانش قبلی.
- $\alpha[r + \gamma V_t(s')]$: سهم تجربه جدید.

۶.۲ تابع Q

- تابع Q (Q Function): ارزش انجام عمل خاص a در حالت خاص s .
- تفاوت اصلی: $V(s)$ ارزش خود حالت است؛ $Q(s, a)$ ارزش یک عمل در آن حالت.
- رابطه میان V و Q :

$$V(s) = \max_a Q(s, a)$$

- تابع احتمال گذار (Transition Function) با $T(s, a, s')$ نشان داده می‌شود: احتمال رسیدن از s به s' با انجام a .

محاسبه Q در محیط تصادفی

$$Q(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V(s')]$$

۷.۲ الگوریتم Q-Learning

- در Q-Learning ارزش عمل‌ها در حالت‌ها مستقیماً به‌روزرسانی می‌شود؛ نه فقط ارزش خود حالت‌ها.
- عبارت $\max_{a'} Q_t(s', a')$ بهترین عمل ممکن در حالت بعدی را نشان می‌دهد.

فرمول به‌روزرسانی Q-Learning

$$Q_{t+1}(s, a) = (1 - \alpha)Q_t(s, a) + \alpha \left[r + \gamma \max_{a'} Q_t(s', a') \right]$$

۸.۲ موازنه اکتشاف و بهره‌برداری

- بهره‌برداری (Exploitation): استفاده از بهترین تجربه‌های شناخته‌شده قبلی؛ انتخاب حریصانه یا Greedy.
- اکتشاف (Exploration): فرصت دادن به عمل‌های کمتر امتحان‌شده برای کشف گزینه‌های احتمالاً بهتر.
- تصمیم‌گیری مؤثر معمولاً به تعادل میان این دو نیاز دارد.

۹.۲ Active RL و Passive RL

- یادگیری تقویتی ایستا (Passive RL):

- تمرکز بیشتر بر بهره‌برداری و تجربه‌های قبلی.
- تمایل کمتر به امتحان گزینه‌های جدید.
- امتیاز عمل:

$$\text{Score}(s, a) = Q(s, a)$$

- یادگیری تقویتی پویا (Active RL):

- عدم قطعیت را نیز در انتخاب عمل وارد می‌کند.
- میان اکتشاف و بهره‌برداری تعادل ایجاد می‌کند.
- امتیاز عمل:

$$\text{Score}(s, a) = Q(s, a) + \beta U(s, a)$$

- $U(s, a)$: میزان عدم قطعیت درباره عمل؛ برای عمل کمتر امتحان‌شده بیشتر است.
- β : میزان اهمیت عدم قطعیت در تصمیم‌عامل.
- مشابه روش کران اطمینان بالا (Upper Confidence Bound; UCB).