

خلاصه امتحانی فصل ۶

شبکه‌های اسپایکی و محاسبات نورومورفیک

مرور تفکیک‌شده مفاهیم، مقایسه‌ها و فرمول‌ها

بخش اول: مبانی شبکه‌های عصبی اسپایکی

۱.۱ چرا شبکه‌های اسپایکی؟

- شبکه عصبی اسپایکی (Spiking Neural Network; SNN): شبکه‌ای که اطلاعات را با رخدادهای گسسته زمانی، یعنی وجود یا نبود اسپایک، منتقل می‌کند.
- هدف: نزدیک شدن به پردازش زیستی مغز با در نظر گرفتن زمان، رویداد، یادگیری محلی و مصرف انرژی.
- در مغز، یادگیری عمدتاً محلی است؛ هر نورون بر اساس ورودی‌ها و وضعیت خود عمل می‌کند و backpropagation کلاسیک و سراسری وجود ندارد.

۲.۱ مقایسه ANN و SNN

- (Artificial Neural Network) ANN:
 - ورودی و خروجی نورون معمولاً مقدارهای پیوسته‌اند.
 - جمع وزن‌دار، bias و تابع فعال‌ساز، خروجی عددی تولید می‌کنند.
 - وزن‌ها معمولاً با خطای نهایی و backpropagation سراسری اصلاح می‌شوند.
 - بیشتر لایه‌ها در هر گام محاسباتی فعال‌اند.
- (Spiking Neural Network) SNN:
 - ورودی و خروجی، دنباله‌ای زمانی از اسپایک‌های صفر و یک است:

$$S = [0, 1, 0, 1, 1, 0, \dots]$$

- ۱: اسپایک رخ داده است؛ ۰: اسپایکی وجود ندارد.
- ترتیب و فاصله زمانی اسپایک‌ها بخشی از اطلاعات‌اند.
- محاسبه رویدادمحور و بالقوه محلی و کم‌مصرف است.

۳.۱ ساختار نورون زیستی

- دندريت: دریافت سیگنال نورون‌های دیگر از طریق سیناپس‌ها.
- سوما یا بدنه سلولی (Soma): جمع اثر ورودی‌ها و تصمیم برای شلیک.
- آکسون: انتقال اسپایک خروجی به نورون‌های دیگر.
- سیناپس: محل اتصال آکسون یک نورون به دندريت نورون بعدی.
- نورون پیش سیناپسی (Presynaptic Neuron): فرستنده اطلاعات.
- نورون پس سیناپسی (Postsynaptic Neuron): دریافت‌کننده اطلاعات.

۴.۱ اسپایک و محاسبه زمان‌محور

- هر اسپایک ورودی در وزن سیناپسی خود ضرب می‌شود:

$$S_i(t)W_i$$

- اثر اسپایک‌ها در ولتاژ غشا جمع می‌شود؛ عبور ولتاژ از آستانه، اسپایک خروجی ایجاد می‌کند.

- برخلاف ANN، فقط تعداد اسپایک‌ها مهم نیست؛ زمان وقوع، ترتیب و فاصله آن‌ها نیز مهم است.
- هر رخداد می‌تواند همان لحظه پردازش را فعال کند؛ لازم نیست کل شبکه دائماً محاسبه انجام دهد.

۵.۱ مدل LIF

- مدل (Leaky Integrate-and-Fire) LIF: مدل ساده نورو اسپایکی با چهار رفتار اصلی:
 - تجمع (Integration): جمع اثر ورودی‌های وزن‌دار.
 - شلیک (Fire): تولید اسپایک پس از عبور از آستانه.
 - نشت (Leak): کاهش تدریجی ولتاژ در نبود ورودی کافی.
 - دوره تحریک‌ناپذیری (Refractory Period): توقف کوتاه فعالیت یا دشوار شدن شلیک مجدد پس از اسپایک.

معادلات اصلی LIF

$$V(t + 1) = \lambda V(t) + I(t)$$

$$I(t) = \sum_i W_i S_i(t)$$

$$V(t + 1) \geq V_{\text{threshold}} \implies \text{شلیک اسپایک}$$

- $V(t)$: ولتاژ قبلی غشا؛ λ : ضریب نشت؛ $I(t)$: جریان ورودی.

- پس از شلیک، ولتاژ نورو reset می‌شود تا انباشت قبلی بی‌نهایت ادامه پیدا نکند.

۶.۱ پردازش رویدادمحور و مصرف انرژی

- شبکه می‌تواند همیشه آماده‌باش باشد، اما فقط با رسیدن اسپایک محاسبه انجام دهد.
- ورودی صفر معمولاً محاسبه سنگین ایجاد نمی‌کند؛ بنابراین فعالیت پراکنده و رویدادمحور، مصرف انرژی را کم می‌کند.
- کاربردها: تشخیص کلمه بیدارباش، سمعک، سامانه شنود کم‌مصرف، ربات، پهپاد، سامانه‌های embedded و واکنش بلادرنگ.

بخش دوم: یادگیری در شبکه‌های اسپایکی

۱.۲ تغییر وزن و قانون Hebb

- یادگیری در سطح سیناپس با تغییر وزن نمایش داده می‌شود:

$$\Delta W$$

- مسیرهایی که بارها فعال می‌شوند، وزن بیشتری می‌گیرند و عبور اطلاعات از آن‌ها آسان‌تر می‌شود.
- یادگیری هبی (Hebbian Learning): اگر دو نورو مرتب در ارتباط با هم فعال شوند، اتصال آن‌ها تقویت می‌شود:

$$\text{Fire together, wire together}$$

- «با هم» الزاماً هم‌زمانی دقیق نیست؛ پیش‌سیناپسی شلیک می‌کند و پس‌سیناپسی کمی بعد فعال می‌شود.

۲.۲ STDP و نقش ترتیب زمانی

- STDP یا Spike-Timing-Dependent Plasticity: تغییر وزن بر اساس ترتیب و فاصله زمانی اسپایک‌های دو نورو.
- اختلاف زمانی:

$$\Delta t = t_{\text{post}} - t_{\text{pre}}$$

• **LTP (Long-Term Potentiation):**

$$t_{\text{pre}} < t_{\text{post}} \iff \Delta t > 0 \implies \Delta W > 0$$

پیش‌سیناپسی زودتر شلیک کرده؛ رابطه‌ی علی محتمل است و وزن تقویت می‌شود.

• **LTD (Long-Term Depression):**

$$t_{\text{pre}} > t_{\text{post}} \iff \Delta t < 0 \implies \Delta W < 0$$

پس‌سیناپسی زودتر فعال شده؛ پیش‌سیناپسی احتمالاً علت آن نبوده و وزن تضعیف می‌شود.

پنجره زمانی STDP

$$\Delta W = A_+ e^{-\Delta t / \tau_+} \quad (\Delta t > 0)$$

$$\Delta W = -A_- e^{\Delta t / \tau_-} \quad (\Delta t < 0)$$

- A_+, A_- : دامنه تقویت و تضعیف؛ τ_+, τ_- : ثابت‌های زمانی.
- هرچه $|\Delta t|$ کوچک‌تر باشد، ارتباط زمانی و مقدار تغییر وزن بیشتر است.
- اختلاف زمانی زمانی معنا دارد که هر دو نورون اسپایک زده باشند.

۳.۲ Reward-Modulated STDP

• STDP تعیین می‌کند کدام سیناپس‌ها از نظر زمانی در رفتار نقش داشته‌اند.

• خطای پیش‌بینی پاداش تعیین می‌کند تغییر آن سیناپس‌ها در چه جهتی باشد:

$$\delta = R_{\text{actual}} - R_{\text{predicted}}$$

• ردپای شایستگی (Eligibility Trace): رد موقت سیناپس‌های مرتبط که تا رسیدن پاداش حفظ می‌شود.

تغییر وزن با تعدیل پاداش

$$\Delta W = \eta \times \delta \times E(t)$$

- η : نرخ یادگیری؛ δ : خطای پیش‌بینی پاداش؛ $E(t)$: اثر STDP یا ردپای شایستگی.
- $\delta > 0$: سیناپس مرتبط تقویت می‌شود؛ $\delta < 0$: همان سیناپس می‌تواند تضعیف شود.

نکته مفهومی

STDP مسئله «چه کسی در رفتار نقش داشت؟» و سیگنال پاداش مسئله «نتیجه خوب بود یا بد؟» را حل می‌کند. ترکیب آن‌ها به مسئله نسبت‌دادن اعتبار کمک می‌کند.

بخش سوم: شبکه‌های اسپایکی عمیق**۱.۳ SNN پایه به Deep SNN**

• **Deep SNN**: چند لایه اسپایکی متوالی که خروجی اسپایکی هر لایه، ورودی لایه بعد است.

• در هر لایه این زنجیره تکرار می‌شود:

اسپایک → آستانه → ولتاژ → جریان → وزن → اسپایک

- خروجی دودویی نورو:

$$S = \begin{cases} 1 & V > \theta \\ 0 & V \leq \theta \end{cases}$$

- اثر ورودی‌های متعدد:

$$I = xw, \quad V = x_1w_1 + x_2w_2 + x_3w_3 + \dots$$

۲.۳ الهام زیستی از سلسله‌مراتب مغز

- در بینایی، پردازش از ویژگی‌های ساده در V1 به بازنمایی‌های پیچیده‌تر در V2/V3/V4، MT/V5 و IT می‌رسد.
- لایه‌های اولیه: لبه، خط، جهت و رنگ؛ لایه‌های بالاتر: شکل، چهره، هویت و مفهوم شیء.
- مسیر شکمی (Ventral): تشخیص «چیستی» شیء یا What.
- مسیر پشتی (Dorsal): «کجایی/چگونگی»، حرکت و تعامل یا Where/How.
- در لامسه، S1 اطلاعات اولیه مانند لمس، درد و دما؛ S2 اطلاعات ترکیبی‌تر و انتزاعی‌تر را پردازش می‌کند.

۳.۳ مزیت انرژی و محدودیت STDP

- مغز با وجود پیچیدگی زیاد حدود ۲۰ وات مصرف می‌کند؛ رویداد محوری و محلی بودن محاسبه از دلایل بهینگی آن‌اند.
- STDP برای شبکه کوچک، یادگیری بدون ناظر، برخط و زیستی‌تر مناسب است.
- در شبکه عمیق، STDP به‌تنهایی با همگرایی دشوار، دقت کمتر و مشکل تنظیم وزن‌های چند لایه روبه‌رو است.
- برای Deep SNN نظارت‌شده معمولاً به روشی شبیه backpropagation نیاز است.

۴.۳ مسئله مشتق‌پذیری و Surrogate Gradient

- تابع اسپایک یک تابع پله‌ای است و تقریباً همه‌جا مشتق صفر دارد؛ پس گرادینت لازم برای پس‌انتشار عبور نمی‌کند.
- **Surrogate Gradient**: استفاده از یک تابع نرم و مشتق‌پذیر فقط برای محاسبه گرادینت.
- در گذر رو به جلو: تابع واقعی اسپایک و خروجی صفر یا یک استفاده می‌شود.
- در گذر رو به عقب: مشتق تابع جایگزین، مانند تقریب نرم شیبه sigmoid، استفاده می‌شود.
- تابع جایگزین با تابع فعال‌ساز معمولی فرق دارد: رفتار forward را تغییر نمی‌دهد و فقط ابزار آموزش است.

۵.۳ Feedforward و وضعیت زمانی نورو

به‌روزرسانی جریان، ولتاژ و اسپایک

$$I[t+1] = \alpha I[t] + S[t]W$$

$$V[t+1] = \beta V[t] + I[t+1]$$

$$S[t+1] = \begin{cases} 1 & V[t+1] > \theta \\ 0 & V[t+1] \leq \theta \end{cases}$$

- α : ضریب کاهش جریان؛ β : ضریب نشت ولتاژ؛ θ : آستانه.
- پس از اسپایک، ولتاژ و گاهی جریان ریست یا کاهش می‌یابد.

۶.۳ Backpropagation با گرادیان جایگزین

خطا و به‌روزرسانی وزن

$$E = \frac{1}{2}(T - O)^2$$

$$W_{\text{new}} = W_{\text{old}} - \eta \frac{\partial E}{\partial W}$$

$$\frac{\partial E}{\partial W} = \underbrace{\frac{\partial E}{\partial O}}_{O-T} \cdot \underbrace{\frac{\partial O}{\partial \text{Net}}}_{\text{مشتق جایگزین}} \cdot \underbrace{\frac{\partial \text{Net}}{\partial W}}_X, \quad \text{Net} = XW$$

۷.۳ مثال عددی گرادیان جایگزین

۱. داده‌ها:

$$X = 2, \quad W = 0.4, \quad \theta = 1, \quad T = 1, \quad V_0 = 0$$

۲. گذر رو به جلو:

$$\text{Net} = XW = 2(0.4) = 0.8 < 1 \implies O = 0$$

۳. با فرض مشتق جایگزین ۰.۲۵:

$$\frac{\partial E}{\partial W} = (O - T)(0.25)X = (-1)(0.25)(2) = -0.5$$

۴. با $\eta = 0.1$:

$$W_{\text{new}} = 0.4 - 0.1(-0.5) = 0.45$$

وزن افزایش می‌یابد تا نوروں دفعه بعد آسان‌تر به آستانه برسد.

۸.۳ STDP در برابر Surrogate Gradient

- **STDP**: شبکه کوچک یا کم‌عمق، بدون ناظر، یادگیری برخط، قانون محلی وزیستی‌تر.
- **Surrogate Gradient**: شبکه عمیق، نظارت‌شده، مقایسه خروجی با برچسب و تنظیم دقیق چندین لایه.
- گرادیان جایگزین فقط در آموزش استفاده می‌شود.
- پس از آموزش، استنتاج همچنان اسپایکی، رویدادمحور و مناسب سخت‌افزار نورومورفیک است.

جمع‌بندی سریع

Basic SNN $\xrightarrow{\text{STDP}}$ Local Learning Deep SNN $\xrightarrow{\text{Surrogate Gradient}}$ Deep Training

SNN پایه با STDP به یادگیری محلی و Deep SNN با گرادیان جایگزین به آموزش چندلایه می‌رسد. ارزش عملی اصلی SNN در اجرای کم‌مصرف روی ربات، پهپاد، سامانه نهفته و سخت‌افزار نورومورفیک دیده می‌شود.