

خلاصه امتحانی فصل ۸

هم‌ترازی مغز، کدگذاری عصبی و استدلال

مرور تفکیک‌شده نظریه‌ها، مراحل، مقایسه‌ها و فرمول‌ها

بخش اول: کدگذاری و رمزگشایی عصبی

۱.۱ Neural Decoding و Neural Encoding

- کدگذاری عصبی (Neural Encoding): تبدیل محرک خارجی مانند صدا، تصویر یا لمس به فعالیت عصبی.
- رمزگشایی عصبی (Neural Decoding): بازسازی محرک، نیت، فرمان، رفتار یا متن از روی فعالیت مغزی.

فرمان یا رفتار → فعالیت مغزی → محرک خارجی

- Encoding مسیر اول و Decoding تلاش برای پیمودن مسیر معکوس است.

۲.۱ سه نظریه اصلی Neural Coding

- **Grandmother Cell** (Grandmother Cell Theory):
 - یک نورون یا گروه بسیار کوچک، نماینده اختصاصی یک مفهوم است.
 - مزیت: تفسیرپذیری بالا؛ ضعف: آسیب‌پذیری، ظرفیت نامعقول و نیاز به نماینده برای مفاهیم بسیار زیاد.
 - شباهت محاسباتی: نودهای اختصاصی کلاس در لایه خروجی.
- کدگذاری جمعیتی (Population Coding):
 - تصمیم از مشارکت تعداد زیادی نورون با شدت و وزن متفاوت ساخته می‌شود:

$$\sum_i W_i X_i$$

- مزایا: پایداری در برابر آسیب، دقت و ظرفیت ترکیبی بیشتر.
- ضعف‌ها: مصرف انرژی بیشتر، توزیع‌شدگی و تفسیرپذیری کمتر.
- کدگذاری تنک (Sparse Coding):
 - فقط زیرمجموعه‌ای کوچک و مرتبط، مثلاً حدود ۵٪ تا ۲۰٪ از نورون‌ها برای هر وظیفه فعال می‌شوند.
 - حالت میانی: پایداری بهتر از بازنمایی اختصاصی، انرژی و تفسیرپذیری بهتر از کدگذاری کاملاً جمعیتی.

۳.۱ مقایسه و ترکیب نظریه‌ها

Population Coding → لایه‌های ابتدایی
 Sparse Coding → لایه‌های میانی
 Grandmother-like → لایه‌های انتهایی

- ابتدایی: ویژگی‌های خام مانند فرکانس، واج، لبه، جهت و رنگ؛ توزیع‌شده و کم‌تفسیر.
- میانی: شکل و ویژگی‌های انتزاعی‌تر؛ گروه‌های منتخب فعال می‌شوند.
- انتهایی: کلاس یا مفهوم مشخص؛ بازنمایی اختصاصی‌تر.
- Symbolic AI بیشتر به Sparse Coding نزدیک است: مجموعه‌ای منتخب از قواعد و ویژگی‌های صریح در تصمیم نقش دارند.

۴.۱ Brain-to-Text و Brain-to-QWERTY

- نمونه مطرح‌شده: پژوهش Meta در سال ۲۰۲۵ دربارهٔ Brain-to-QWERTY.
- هدف محدود Brain-to-QWERTY: رمزگشایی کلیدهایی که فرد هنگام تایپ فشار داده یا قصد فشاردادن آن‌ها را داشته است؛ نه خواندن تمام افکار.
- مرحله آموزش:
- ۱. نمایش و خواندن متن توسط فرد.
- ۲. تایپ متن با صفحه‌کلید QWERTY.
- ۳. ثبت هم‌زمان سیگنال مغزی.
- ۴. مقایسه خروجی مدل با متن یا کلیدهای مورد انتظار.
- ۵. محاسبه خطا، اصلاح وزن‌ها و کالیبراسیون برای همان فرد.
- فاز آزمون: متن هدف نامعلوم است و مدل فقط از فعالیت مغزی، متن یا نیت تایپ را بازسازی می‌کند.

معماری کلی Brain-to-Text

متن → Language Model → Decoder-only Transformer → ویژگی میانی → CNN → سیگنال مغزی

- CNN: استخراج ویژگی از سیگنال خام.
- Transformer: مدل‌کردن توالی کلیدها یا حروف.
- Language Model: اصلاح کانتکستی و خطاهایی مانند «سلام» به «سلام».

۵.۱ کاربرد و مقایسه با Neuralink

- کاربرد: ارتباط برای افراد دچار آسیب نخاعی یا محدودیت شدید حرکتی؛ تبدیل نیت ذهنی به متن یا فرمان.
- Brain-to-QWERTY: دامنه محدود به تایپ و کلیدهای صفحه‌کلید.
- Neuralink: ایمپلنت تهاجمی برای تبدیل نیت حرکتی به کنترل ماوس، کلیک یا ابزار خارجی.

۶.۱ روش‌های ثبت فعالیت مغزی

- fMRI: غیرتهاجمی، مبتنی بر جریان خون، رزولوشن مکانی خوب و زمانی ضعیف در مقیاس ثانیه.
- EEG: غیرتهاجمی، ثبت الکتریکی از پوست سر، رزولوشن زمانی خوب در حد میلی‌ثانیه و مکانی ضعیف‌تر.
- ایمپلنت مغزی: تهاجمی، نزدیک به نورون‌ها و دارای رزولوشن زمانی و مکانی بهتر؛ همراه با خطر جراحی، پایداری و مسائل اخلاقی.

۷.۱ چالش‌ها و مسیر آینده

- Plasticity (Plasticity): مغز با یادگیری، خستگی و زمان تغییر می‌کند؛ مدل کالیبره‌شده ممکن است بعداً همان توزیع سیگنال را نبیند.
- تعمیم بین افراد: نقشه مغزی مانند اثر انگشت متفاوت است؛ مدل یک فرد الزاماً روی دیگری کار نمی‌کند.
- چندوجهی بودن (Multimodality): متن، تصویر، صدا، حافظه، توجه و هیجان هم‌زمان بر فعالیت مغز اثر دارند.
- هدف سخت‌افزاری: سنسور غیرتهاجمی، پوشیدنی، دقیق، کم‌مصرف و کم‌حرارت.
- Neuromorphic Hardware (Neuromorphic): پردازش رویدادمحور به جای پردازش دائم مبتنی بر کلاک.

Spike/Event → Processing

۸.۱ وزن نهایی نورونی

عوامل شکل دهنده وزن

$$\text{مقداردهی اولیه} + \text{ترجیح مکانی} + \text{Hebbian Learning} = \text{وزن نهایی}$$

- قانون Hebb: هم‌فعالی مکرر، اتصال را تقویت می‌کند.
- ترجیح مکانی/عملکردی: نورون‌های سازگار با جهت یا کار خاص فعالیت بیشتری دارند.
- مقداردهی اولیه: تفاوت‌های اولیه افراد بر پاسخ نهایی اثر می‌گذارد.

بخش دوم: Brain Score و Brain Alignment

۱.۲ ایده اصلی هم‌ترازی

- فرضیه بازنمایی افلاطونی (Platonic Representation Hypothesis): پشت بازنمایی‌های ظاهری، یک مفهوم یا حقیقت زیرین مشترک وجود دارد.
 - این حقیقت زیرین را می‌توان با متغیر پنهان Z نشان داد؛ خود Z مستقیماً در دسترس نیست.
 - تصویر، متن، صدا، رفتار، فعالیت مغزی و hidden state مدل، بازنمایی‌های متفاوت همان Z مشترک‌اند:
- $$Z \rightarrow \{\text{متن، تصویر، رفتار، مغز، بازنمایی مدل}\}$$
- پاسخ درست به تنهایی فهم را ثابت نمی‌کند؛ مدل ممکن است الگوی سطحی را حفظ کرده باشد.
 - مدل عمیق‌تر باید از پوسته ظاهری عبور کند و ویژگی انتزاعی و رابطه علی را حفظ کند؛ مثلاً «سیب کپک‌زده» را با وجود تغییر ظاهر همچنان سیب تشخیص دهد.
 - **Brain Alignment**: سنجش اینکه بازنمایی‌های میانی مدل تا چه حد با بازنمایی‌های مغز انسان قابل نگاشت و هم‌راستا هستند.
 - اثبات قطعی «فهم» ممکن نیست؛ هدف عملی، یافتن تقاطعی است که مدل در آن‌ها از معنا یا رفتار انسان فاصله دارد.

۲.۲ طراحی آزمایش هم‌ترازی

۱. تعریف بخش‌های میانی مغز با Brain Parcellation.
۲. انتخاب وظیفه مناسب: زبانی، پیش‌بینی، استدلالی، علی یا چندوجهی.
۳. ارائه محرک یکسان به انسان و مدل.
۴. استخراج fMRI/رفتار انسان و hidden state‌های مدل.
۵. تعریف امتیاز با correlation، similarity یا loss.

۳.۲ آزمایش Brain Score

- مدل اصلی freeze می‌شود؛ هدف ارزیابی بازنمایی موجود است.
- از لایه‌های مدل بردارهایی مانند v_1, v_2, v_3 و از انسان fMRI و رفتارهایی مانند زمان خواندن گرفته می‌شود.
- یک مدل نگاشت (Mapping Model) ساده، معمولاً خطی، یاد می‌گیرد:

$$\text{سیگنال مغزی یا رفتار انسان} \rightarrow \text{بازنمایی مدل}$$

- آموزش: یادگیری نگاشت روی متن‌های مشترک؛ آزمون: پیش‌بینی پاسخ مغز/رفتار برای متن جدید و مقایسه با داده واقعی.
- امتیاز می‌تواند ترکیبی از هم‌ترازی fMRI، خروجی، زمان خواندن و پیش‌بینی باشد.

۴.۲ اهمیت Next Word Prediction

- وظایف بررسی‌شده: QA، انسجام، entailment، شباهت جمله و پیش‌بینی واژه بعدی.
- همبستگی مثبت مهم‌تر در Next Word Prediction دیده شد؛ مغز دائماً پیش‌بینی می‌کند.
- جمله قابل‌پیش‌بینی: اطمینان مدل بیشتر و خواندن انسان سریع‌تر؛ عبارت غیرمنتظره: اطمینان کمتر و مکث بیشتر.

۵.۲ Brain Parcellation: واحدها

- **Voxel (Voxel)**: واحد مکعبی اندازه‌گیری در fMRI؛ نه یک مرز طبیعی زیستی.
- **Parcel (Parcel)**: گروهی از وکسل‌ها با ویژگی مشترک.
- **Atlas (Atlas)**: مجموعه‌ای از پارسل‌ها و نقشه تقسیم‌بندی مغز.
- **ROI (Region of Interest)**: ناحیه منتخب متناسب با وظیفه، مثلاً نواحی زبان.

اطلس/افرازبندی → یک پارسل → چند وکسل

۶.۲ سیگنال BOLD

BOLD = Blood Oxygen Level Dependent

- شاخص تغییر اکسیژن خون و نشانه غیرمستقیم فعالیت عصبی.
- برای هر وکسل یک سری زمانی داریم؛ میانگین وکسل‌های یک پارسل، بازنمایی زمانی آن پارسل را می‌سازد.
- مثال: سه وکسل در چهار زمان $\Rightarrow$ ماتریس 3×4 ، سپس بردار میانگین پارسل.

۷.۲ روش‌های Parcellation

- آناتومیک: تقسیم بر اساس محل و ساختار فیزیکی، مانند V1, V2, V4, IT.
- **Functional Parcellation (Functional Parcellation)**: گروه‌بندی نواحی دور یا نزدیک بر اساس هم‌فعال‌شدن و کارکرد مشترک.
- **Atlas (Atlas)**: استفاده از تقسیم‌بندی از پیش ساخته‌شده.
- **Localizer (Localizer)**: یافتن ناحیه‌های فعال با اجرای همان وظیفه روی شرکت‌کننده.

۸.۲ شبکه‌های هفت‌گانه Yeo

۱. **Visual**: پردازش دیداری، عمدتاً بخش پس‌سری.
۲. **Somatomotor**: حس بدنی، حرکت و هماهنگی عضلات.
۳. **Dorsal Attention**: توجه ارادی و درون‌هدایت‌شده.
۴. **Ventral Attention**: توجه ناگهانی ناشی از محرک بیرونی.
۵. **Frontoparietal**: کنترل، تصمیم‌گیری، هماهنگی چند وظیفه و رفتار.
۶. **Default Mode Network; DMN**: استراحت، تفکر آزاد، خیال‌پردازی و ایده‌پردازی.
۷. **Limbic**: احساس، هیجان و پردازش عاطفی.

۹.۲ Resting State و همبستگی

- استراحت به معنای خاموشی مغز نیست؛ شبکه‌ها همچنان فعال و در حال پیش‌بینی‌اند.

- مغز حدود ۲۰٪ انرژی بدن را مصرف می‌کند؛ وظیفه شناختی بیشتر الگوی شبکه‌ها را تغییر می‌دهد و افزایش انرژی نسبت به خط پایه محدود است.
- ساخت افزایشی کارکردی:
 ۱. گرفتن سری زمانی BOLD هر وکسل؛
 ۲. محاسبه همبستگی سری‌ها؛
 ۳. خوشه‌بندی وکسل‌های با همبستگی بالا؛
 ۴. در نظر گرفتن هر خوشه به عنوان پارسل یا شبکه.
- **Task-Positive** (Task-Positive): هنگام انجام وظیفه فعال‌ترند؛ مثال‌ها: توجه پشتی، توجه شکمی و فرونتوپاریتال.
- **Task-Negative** (Task-Negative): با شروع وظیفه کاهش فعالیت دارند؛ مثال اصلی: DMN.

مثال سریع Task-Positive و Task-Negative

- مطالعه متمرکز یا حل مسئله: شبکه‌های توجه و فرونتوپاریتال بالا می‌روند و DMN معمولاً کاهش می‌یابد.
- استراحت، خیال‌پردازی و تفکر آزاد: DMN فعال‌تر است و شبکه‌های وظیفه‌محور فعالیت کمتری دارند.
- این رابطه مطلق و روشن/خاموشی نیست؛ الگوی فعالیت نسبی شبکه‌ها تغییر می‌کند.

۱۰.۲ بازگشت به Brain Alignment

Parcel/BOLD $\longleftrightarrow$ Correlation/Similarity Hidden State

- همبستگی بالاتر یعنی هم‌ترازی بازنمایی بیشتر، نه اثبات قطعی فهم حقیقی.
- وظایف سخت‌تر مانند استنتاج، کشف قانون و تشخیص مغالطه برای آزمون معنا مناسب‌ترند.
- ۱. تقسیم مغز به پارسل‌های کارکردی.
- ۲. استخراج سیگنال BOLD یا بازنمایی زمانی هر پارسل.
- ۳. استخراج hidden state لایه‌های میانی مدل.
- ۴. محاسبه correlation یا similarity میان بازنمایی مغز و مدل.

بخش سوم: استدلال، قیاس و هم‌ترازی خطا

۱.۳ چرا پاسخ درست کافی نیست؟

- هم‌ترازی فقط شباهت پاسخ نهایی نیست؛ باید الگوی خطا و مسیر رسیدن به پاسخ نیز مقایسه شود.
- مدل هم‌تراز باید تا حدی در همان موقعیت‌هایی خطا کند که انسان‌ها خطا می‌کنند.
- دقت بیشتر از انسان الزاماً به معنای فهم یا استدلال انسانی نیست.
- برخی سوگیری‌ها و خطاهای شناختی را می‌توان بهینه‌سازی تکاملی دانست: فیلتر اطلاعات برای کاهش انرژی و تصمیم سریع‌تر برای بقا؛ بنابراین هر خطای انسانی صرفاً «باگ» نیست.
- **Pareidolia** (Pareidolia): دیدن چهره یا الگوی آشنا در ابر یا اشیای بی‌جان؛ خطای ادراکی که می‌تواند از نظر بقا و تعامل اجتماعی مفید باشد.

۲.۳ System 1 و System 2

- **System 1**: سریع، کم‌هزینه، شهودی، مبتنی بر تجربه و prior knowledge.

- **System 2**: کند، پرهزینه، تحلیلی و نیازمند بررسی و اثبات.
- تفکر انتقادی یعنی در موقعیت لازم از پاسخ پیش فرض سیستم ۱ عبور و سیستم ۲ را فعال کنیم.

۳.۳ انواع Reasoning

- قیاسی (Deductive): نتیجه ضروری از مقدمات.
- استقرایی (Inductive): تعمیم از نمونه‌ها؛ نتیجه احتمالی.
- بهترین تبیین (Abductive): انتخاب محتمل‌ترین توضیح برای مشاهده.
- تمرکز فصل: قیاس صوری (Syllogistic Reasoning).

۴.۳ ساختار Syllogism

- دو مقدمه و یک نتیجه:
- $$\text{Premise ۱} + \text{Premise ۲} \longrightarrow \text{Conclusion}$$
- **Middle Term** (Middle Term): ترم مشترک میان دو مقدمه که آن‌ها را به هم متصل می‌کند؛ بدون آن قیاس شکل نمی‌گیرد.

۵.۳ چهار Mode

- **A** - کلی مثبت: All A are B
- **I** - جزئی مثبت: Some A are B
- **E** - کلی منفی: No A are B
- **O** - جزئی منفی: Some A are not B

۶.۳ Figure ها و تعداد فرم‌ها

Figure ۱	Figure ۲	Figure ۳	Figure ۴
$A - B$	$B - A$	$A - B$	$B - A$
$B - C$	$C - B$	$C - B$	$B - C$

- سه گزاره، هر کدام با چهار جایگاه ترم: Mode چهار و چهار جایگاه ترم:

$$\text{فرم ممکن } ۴ \times ۴ \times ۴ = ۶۴$$

- در صورت بندی فصل: ۲۷ فرم دارای نتیجه معتبر و ۳۷ فرم دارای **NVC** (No Valid Conclusion).

۷.۳ نتیجه معتبر و Barbara

- **Valid Conclusion** (Valid Conclusion): نتیجه‌ای که در همه حالت‌های ممکن درست باشد و هیچ مثال نقضی نداشته باشد.

فرم معتبر Barbara یا ۱ - (AAA)

All A are B

All B are C

∴ All A are C

- درست بودن نتیجه در بعضی حالت‌ها کافی نیست؛ باید در تمام حالت‌ها برقرار باشد.

- نمودار ون ابزار بررسی وجود مثال نقض و اعتبار نتیجه است.

۸.۳ قیاس به عنوان آزمون Brain Alignment

- هر ۶۴ فرم به انسان و مدل داده می‌شود؛ سپس دقت و مهم‌تر از آن، توزیع پاسخ و خطا مقایسه می‌شود.
- اگر مدل همیشه درست باشد اما در فرم‌های دشوار شبیه انسان خطا نکند، الزاماً هم‌تراز نیست.
- انسان برای تمام فرم‌های منطقی بهینه نشده؛ زندگی واقعی بیشتر به تصمیم سریع، تجربه، بایاس و مغالطه وابسته است.

۹.۳ زبان طبیعی و دیتاست Avicenna

- تبدیل A, B, C به زبان طبیعی مسئله را دشوار می‌کند: مدل باید ترم میانی، رابطه منطقی، مغالطه و NVC را تشخیص دهد.
- دیتاست Avicenna: حدود ۶۰۰۰ نمونه قیاس در زبان طبیعی.
- اجزای هر نمونه:
 - Premise 1 و Premise 2
 - Syllogistic Relation
 - Conclusion یا NVC
- اشتراک واژگانی الزاماً ترم میانی نیست؛ «شیر جنگل» و «شیر آب» واژه مشترک اما معنای متفاوت دارند.

۱۰.۳ Syllogism در برابر Entailment

- **Syllogism** (Syllogism): دو مقدمه با ترم میانی مشترک؛ نتیجه از ترکیب آن‌ها حاصل می‌شود.
- **Entailment** (Entailment): ممکن است یک گزاره و دانش عمومی برای نتیجه‌گیری کافی باشد.
- هر استنتاج زبانی الزاماً قیاس نیست.

۱۱.۳ Prior Knowledge و مغالطه

- «دولت فاسد تورم ایجاد می‌کند؛ ایران تورم دارد؛ پس دولت ایران فاسد است» نامعتبر و شبیه تأیید تالی (Affirming the Consequent) است.
- نارضایتی یا باور قبلی می‌تواند نتیجه نامعتبر را برای سیستم ۱ پذیرفتنی کند.
- برعکس، یک نتیجه قیاسی معتبر درباره رشد اقتصادی ممکن است به علت تجربه شخصی پذیرفته نشود.
- بنابراین اعتبار منطقی و پذیرش روان‌شناختی یکسان نیستند.

۱۲.۳ مدل در برابر انسان

- مدل بزرگ‌تر ممکن است در فرم‌های صوری از انسان دقیق‌تر باشد، اما توزیع خطایش متفاوت بماند.
- پاسخ بهتر می‌تواند حاصل داده بیشتر، حافظه یا دیدن نمونه‌های مشابه باشد؛ نه الزاماً فهم انسانی.
- انسان و مدل هر دو آماری یاد می‌گیرند، اما توزیع تجربه و خطاهای آن‌ها یکسان نیست.
- **Adversarial Data Augmentation** (Adversarial Data Augmentation): شناسایی فرم‌های شکست مدل و افزودن هدفمند نمونه‌های مشابه؛ روشی استفاده‌شده برای بهبود روی Avicenna.

معیار نهایی هم‌ترازی

برای سنجش مدل فقط دقت کافی نیست. باید پاسخ درست، خطاهای انسان، خطاهای مدل، توزیع خطا، بازنمایی‌های میانی، اثر دانش قبلی و تفاوت استدلال صوری با استدلال جهان واقعی را هم‌زمان بررسی کرد.